

Rapport du projet CNAM-NFE204 -  
Etude d'un système de base de  
données NOSQL  
***InfluxDB***

Fabrice DUNAN <fabrice.dunan@laposte.net>

# Table des matières

|   |    |
|---|----|
| 1. Objectif du document .....   | 4  |
| 2. InfluxDB "sur le papier" .....                                       | 4  |
| 2.1. TimeSeries DB, kesako ? .....                                      | 4  |
| 2.2. Historique .....   | 4  |
| 2.3. Modèle commercial, licence et support .....                        | 5  |
| 2.4. Utilisateurs et domaines d'utilisation notoires .....              | 5  |
| 2.5. Les entrailles d'InfluxDB .....                                    | 5  |
| 2.5.1. Fonctions & limites .....  | 5  |
| 2.5.2. Systèmes d'exploitation supportés .....                          | 6  |
| 2.5.3. Choix de conception .....  | 7  |
| 2.6. Ecosystème client .....  | 7  |
| 2.6.1. Client CLI .....   | 7  |
| 2.6.2. API REST .....   | 7  |
| 2.6.3. Langages et bibliothèques InfluxDB .....                         | 7  |
| 2.6.4. La "stack TICK" .....  | 8  |
| 2.6.5. Clients IHM .....  | 8  |
| 2.7. Le modèle de données d'InfluxDB .....                              | 8  |
| 2.7.1. Premier élément : les "measurements" ou mesures .....            | 8  |
| 2.7.2. Second élément "optionnel" : les "tags" .....                    | 8  |
| 2.7.3. Troisième élément : les "fields" ou champs .....                 | 9  |
| 2.7.4. Dernier mais non le moindre : le "timestamp" ou estampille ..... | 9  |
| 2.7.5. La "retention policy" .....                                      | 9  |
| 2.7.6. Les Séries .....   | 10 |
| 2.7.7. Les bonnes pratiques sur la création de schémas .....            | 10 |
| 2.8. Le langage d'interrogation d'InfluxDB : InfluxQL (ou IQL) .....    | 10 |
| 2.8.1. Un langage de requêtes à priori similaire au SQL....             | 10 |
| 2.8.2. ... mais CR-ud pas CRUD ...                                      | 11 |
| 2.8.3. ...et sans jointure.   | 12 |
| 2.8.4. Les fonctions IQL  | 12 |
| 2.9. Protocoles et formats .....  | 12 |
| 3. Utilisation superficielle .....                                      | 13 |
| 3.1. Création (C) .....   | 13 |
| 3.1.1. Base .....   | 13 |
| 3.1.2. "measurements" ou tables .....                                   | 14 |
| 3.1.3. Insertion .....  | 14 |
| 3.2. Interrogation (R) .....  | 15 |
| 3.2.1. Lister les bases .....   | 15 |
| 3.2.2. Informations sur les "measurements" et ses colonnes .....        | 15 |

|   |    |
|---|----|
| 3.2.3. Interrogations "classiques" . . . . .  | 16 |
| 3.3. Mises à jour (U) . . . . .   | 17 |
| 3.4. Suppression... (D) . . . . .   | 18 |
| 3.4.1. ...de bases . . . . .  | 18 |
| 3.4.2. ...de séries . . . . .   | 18 |
| 3.4.3. ...de "measurements" . . . . .   | 19 |
| 3.4.4. Et les points ? . . . . .  | 19 |
| 4. Approfondissement et fonctionnalités SGBD pour une problématique de données massives . . . . . | 20 |
| 4.1. La problématique de données "massives" . . . . .   | 20 |
| 4.2. Choix des données . . . . .  | 20 |
| 4.3. Récupération des données . . . . .   | 21 |
| 4.4. Préparation des données . . . . .  | 21 |
| 4.5. Les choix de modélisation . . . . .  | 22 |
| 4.6. Quel outil choisir pour importer ? . . . . .   | 22 |
| 4.6.1. Logstash . . . . .   | 22 |
| 4.6.2. Telegraf . . . . .   | 22 |
| 4.6.3. API InfluxDB par bibliothèque Python . . . . .   | 23 |
| 4.7. Résoudre les problèmes d'import . . . . .  | 25 |
| 4.7.1. Réduire le nombre de points . . . . .  | 25 |
| 4.7.2. Réduire le nombre de fields . . . . .  | 25 |
| 4.8. Traitement . . . . .   | 29 |
| 4.8.1. Quelques requêtes simples . . . . .  | 29 |
| 4.8.2. "Jouer" avec les "temps" . . . . .   | 30 |
| 4.8.3. Agrégations . . . . .  | 32 |
| 4.8.4. Fonctions de sélection . . . . .   | 32 |
| 4.8.5. Transformation . . . . .   | 33 |
| 5. Un aperçu de l'administration d'InfluxDB . . . . .   | 35 |
| 5.1. Sauvegarde et restauration . . . . .   | 35 |
| 5.2. Gestion des logs . . . . .   | 35 |
| 5.3. Authentification et autorisations . . . . .  | 36 |
| 5.4. Politique de rétention . . . . .   | 36 |
| 5.5. Requêtes en continu ou Continuous request . . . . .  | 37 |
| 5.6. Clustering . . . . .   | 37 |
| 5.6.1. L'architecture d'un cluster InfluxDB . . . . .   | 38 |
| 5.6.2. Création d'un cluster InfluxDB dans le cloud InfluxData / AWS . . . . .                    | 40 |
| 5.6.3. InfluxCloud est insuffisant pour se faire une idée du cluster ! . . . . .                  | 42 |
| 5.6.4. Exploitation du cluster avec l'ensemble des données de l'approfondissement . . . . .       | 43 |
| 6. Conclusion et approfondissements envisageables . . . . .                                       | 47 |
| Appendix A: Annexes . . . . .   | 48 |
| A.1. En savoir plus sur la stack TICK . . . . .   | 48 |
| A.1.1. Architecture . . . . .   | 48 |

|  |    |
|--|----|
| A.1.2. Telegraf .....  | 48 |
| A.1.3. Chronograf .....  | 50 |
| A.1.4. Kapacitor .....   | 50 |
| A.2. Tableaux de synthèse des fonctions IQL .....                                    | 50 |
| A.2.1. Les fonctions d'agrégation .....  | 50 |
| A.2.2. Les fonctions de sélection .....  | 50 |
| A.2.3. Les fonctions de transformation .....   | 51 |
| A.2.4. Prédicteur .....  | 51 |
| A.3. Eléments techniques (Installation, paramétrage...) d'InfluxDB .....             | 51 |
| A.3.1. Matériel de tests .....   | 51 |
| A.3.2. InfluxDB et docker .....  | 51 |
| A.3.3. Logs de démarrage et extinction influxDB .....                                | 52 |
| A.3.4. Ports exposés .....   | 54 |
| A.3.5. Processus .....   | 54 |
| A.3.6. Bibliothèques python clientes .....   | 54 |
| A.3.7. CLI & CLI docker .....  | 55 |
| A.3.8. Endpoints REST d'influxDB .....   | 56 |
| A.3.9. Lancer Telegraf .....   | 56 |
| A.3.10. Lancer Chronograf .....  | 56 |
| A.3.11. Lancer Kapacitor .....   | 57 |
| A.4. Description des variables des données météo .....                               | 57 |
| A.5. Correspondances numer_sta et communes des stations de mesure .....              | 59 |
| A.6. Script de récupération des données Météofrance .....                            | 61 |
| A.7. Scripts import des données MétéoFrance dans InfluxDB .....                      | 62 |
| A.7.1. Le script lauréat modifié pour les besoins du projet .....                    | 62 |
| A.7.2. Un essai d'import avec un script utilisant docker non retenu car limité ..... | 65 |
| A.8. Les caractéristiques du cluster cloud .....                                     | 66 |
| A.9. Des commandes de diagnostic .....   | 67 |
| Références .....   | 68 |
| Bibliographiques .....   | 68 |
| Web .....  | 68 |



[https://gitlab.com/logrus\\_fr/CNAM-projets/NFE204](https://gitlab.com/logrus_fr/CNAM-projets/NFE204)

Fabrice DUNAN <[fabrice.dunan@laposte.net](mailto:fabrice.dunan@laposte.net)>

v1, 2018-05-18

tuteur: P.Rigaux

## Préface : Quel SGBD NOSQL étudier ???

### Partir des données...

En tentant naïvement l'analyse de données ouvertes, on constate souvent l'existence d'une variable de date voire d'horodatage.

L'objet des [séries temporelles](#) ou [séries chronologiques](#) est l'étude des variables au cours du temps. Les algorithmes étudiés dans les autres UE CNAM que l'on a suivi ne se focalisent pas sur l'étude des séries temporelles...Cela n'empêche pas de s'y intéresser !

Des sources de données "Time series" communes : les mesures physiques (des données météo vont être exploitées dans la suite de ce rapport), les données produites par des objets connectés mais aussi la surveillance d'un système d'exploitation de serveur où l'on veut mesurer des métriques système d'un composant comme la CPU, la RAM, le stockage (quantité ou I/O)...tout ce qui fait un serveur peut être ingéré, traité, interrogé au sein d'une base "Time series" et représenté graphiquement pour surveillance, suivi, "capacity planning", etc, ....

Même une application informatique "serveur" comme Gitlab, challenger de GitHub dans le domaine de la [gestion de dépôts Git](#), embarque InfluxDB pour surveiller l'état de sa JVM comme les mesures sur le "Garbage collecting" et d'autres encore. Cette DB "time series" est donc particulièrement adaptée aux outils "devOps". Cette utilisation peut se généraliser à toute surveillance métier pour peu que le métier en question émette périodiquement des données chronologiques.

Les DB "time series" s'adaptent très bien à l'analytique temps réel où les données sont produites et exploitées en temps réel.

### ... un moteur de recherche ? ...

Ces données horodatées sont parfois immuables. C'est le cas des prises de mesure (physique, météo, ressources système informatique..) ou des journaux informatiques.

Les moteurs de recherche étaient de bons candidats.

Pour autant, les SGBD NOSQL vus en cours NFE204 sont exclus des candidats possibles, y compris les moteurs d'indexation comme Elasticsearch ou Solr.

Plutôt qu'étudier un 3<sup>ème</sup> moteur d'indexation, tout aussi adapté à la gestion des données horodatées, on se tournerait bien vers l'originalité de leur compagnon habituel, les DB clé valeur qui sont souvent utilisés comme cache dans un contexte streaming.

### ... ou leur compagnon ?

Hélas, leurs langages de requête étaient trop pauvres, leurs schémas quasi absents et leurs fonctionnalités trop spécialisées. On a finalement écarté l'étude de "SGBD clé valeur" type Riak ou Redis.

### Les SGBD NOSQL "time series"

On revient donc sur l'idée initiale d'étudier un des nombreux SGBD de la famille "time series" étudiés pour ce genre de données.

## Comparatif

L'idée initiale était d'étudier deux membres de cette famille, un par binôme, dans des projets NFE204 distincts, pour ne retenir que le "meilleur" dans les autres projets.

Faute de temps et de coordination, ce comparatif ne sera pas traité.

# 1. Objectif du document

Ce document est le rapport d'étude du SGBD NOSQL "time series" **InfluxDB**. Il a été élaboré dans le cadre de l'UE NFE204, visant à l'obtention du certificat de données massives du CNAM.

Son objectif est à la fois de découvrir le SGBD NOSQL pré-cité, la famille de SGBD à laquelle il appartient, de constituer une base de données documentaire et enfin d'approfondir un ou plusieurs des aspects de ce SGBD.

Il sera constitué tout d'abord d'une première partie de présentation du SGBD, telle qu'on aurait pu la faire en se documentant dans les détails, sans manipulation ni test.

Cette partie sera suivie d'une partie dédiée à l'utilisation unitaire et simpliste de la base.

Les deux points que l'on souhaite approfondir dans InfluxDB, son langage de requêtes et son fonctionnement en tant que cluster, seront couverts par les deux dernières parties :

On expérimentera InfluxDB et son langage de requêtes plus en profondeur et autour d'une thématique de données massives. Seule la partie interaction avec la base de donnée de la problématique sera traitée dans ce document.

Enfin, on survolera la partie administration de la base dans une dernière partie, mais en précisant les aspects cluster d'InfluxDB.

## 2. InfluxDB "sur le papier"

A l'heure de la rédaction de ce document, InfluxDB se maintient selon certaines sources comme la [TSDB leader](#).

Nous allons tenter de décortiquer ce système le plus possible pour comprendre pourquoi il est tant plébiscité. On commence cette enquête par une étude documentaire.

### 2.1. TimeSeries DB, kesako ?

Dans le cas de stockage de résultats de mesures, les SGBDR classiques ne sont pas forcément la panacée.

Un certain nombre d'outils s'y substituaient déjà, comme RRDTool.

Mais l'absence des caractéristiques des SGBD NOSQL comme la gestion de (très) gros volumes de données, parler JSON, une interface REST, un langage de requêtes, la réplication, le partitionnement...ont laissé une place à de nouveaux système capables également de gérer les séries chronologiques, les événements ou les métriques: "Time Series DataBases" (abrégié *TSDB* par la suite).

### 2.2. Historique

Le projet [InfluxDB](#) a démarré en **octobre 2013** par une société du nom d'[Errplane](#) fondée par *Paul Dix* et *Todd Persen*.



Cette société a été initialement financée par un fond d'investissement de la Silicon Valley nommé [Y-combinator](#), connu également pour avoir financé Docker, entre autres.

Après une levée de fonds de 8M\$ en 2014, Errplane change de nom en 2015 pour devenir InfluxData inc. Fin 2016, InfluxData lève 16M\$.

La dernière version en date, publiée en **avril 2018**, est la **1.5.2**.

## 2.3. Modèle commercial, licence et support

Le [modèle économique](#) d'InfluxDB est répandu : la base du SGBD est open source, les fonctionnalités propriétaires (HA, scalabilité, backup/restore avancées...) sont contenues dans la version commerciale **InfluxEntreprise**.

La licence d'utilisation est gratuite pour un unique serveur.

Le code de cette version "community" dite **influxDB OSS** est Open source (licence MIT).

Pour accéder aux fonctionnalités des clusters InfluxDB, une licence commerciale est obligatoire.

Le test du cluster peut être réalisé gratuitement sur une période limitée sur la plateforme Cloud d'Influxdata. Ce test est couvert dans un [chapitre ultérieur du projet](#).

L'offre cloud **InfluxCloud** hébergée par AWS.

Pour l'offre cloud :

- entre 250 et 500\$/mois cloud standard
  - 900 et 1500\$/mois pour le cloud avancé/professionnel
- la distinction se faisant sur les ressources allouées.

Les [gammes de prix des différents services](#) sont détaillées dans le lien précédent.

Le support est fourni par Influxdata.

## 2.4. Utilisateurs et domaines d'utilisation notoires

InfluxDB est utilisé par eBay, Cisco pour ne citer qu'eux...

On résume ci-après les domaines communiqués par InfluxData et déjà mentionnés plus haut :

- IoT et capteurs
- "monitoring DevOps"
- "Analytics" temps réel

## 2.5. Les entrailles d'InfluxDB

Dans ce chapitre, on survole les caractéristiques internes d'InfluxDB.

### 2.5.1. Fonctions & limites

InfluxDB comporte les fonctions listées ci-après, certaines étant la conséquence d'autres :

*SGBD NoSQL "moderne":*

- schéma des données
- langage d'interrogation
- protocoles :
  - HTTP API REST
  - JSON over UDP

#### *Performances et tolérance aux pannes*

- réplication
- partitionnement
- passage à l'échelle
- HA au sein d'un cluster

Certaines des limites sont listées [ici](#), d'autres [là](#). En synthèse ci-dessous, la liste des fonctionnalités qu'InfluxDB n'a pas :

- index secondaires
- procédures stockées
- Fonctions de Map&Reduce
- Clés étrangères
- Transaction
- Jointure

Néanmoins, il paraît nécessaire de rester attentif aux évolutions car dans le monde des SGBD NOSQL, les fonctionnalités tendent à s'harmoniser et le projet InfluxDB est très actif !

### **2.5.2. Systèmes d'exploitation supportés**

Les systèmes d'exploitation sur lesquels peuvent fonctionner influxDB sont les distributions Linux commerciales principales et leurs contreparties libres, certains UNIX libres et un OS commercial.

*Table 1. Tableau des OS supportés*

| nom OS             |          |
|--------------------|----------|
| Ubuntu             | Debian   |
| RHEL               | CentOS   |
| SLES               | OpenSuse |
| FreeBSD/P<br>C-BSD |          |
| MacOSX             |          |

Dans la partie mise en pratique de ce rapport, on utilisera exclusivement InfluxDB sur Ubuntu.

### 2.5.3. Choix de conception

*Langage avec lequel InfluxDB a été développé*

InfluxDB est écrit en Go, le langage créé par Google.

*Moteur d'influxDB*

InfluxDB était initialement fondé sur le moteur clé/valeur **LevelDB de Google**. D'après la documentation, et pour des raisons approfondies dans le lien suivant, il utilise maintenant le moteur [BoltDb](#) écrit en Go.

*Architecture*

InfluxDB OSS est d'un point de vue OS un processus multithreadé qui écoute sur le port **8086**.

On verra plus tard dans ce document, dans le chapitre [ultérieur](#), un focus sur l'architecture cluster d'InfluxDB Entreprise.

## 2.6. Ecosystème client

### 2.6.1. Client CLI

Le client en ligne de commande est présent dans l'installation d'influxdb. On privilégiera son utilisation dans la suite de l'étude.

On trouvera les détails techniques en [annexe](#)

### 2.6.2. API REST

L'API REST complète les moyens pour interagir avec InfluxDB. Elle permet l'exploitation des codes retour HTTP, de l'authentification HTTP, des token JWT pour le SSO, ce, en recevant et envoyant des documents JSON.

Peu utilisée directement dans ce projet, on pourra consulter des détails en [annexe](#). Néanmoins, il faut garder à l'esprit que le CLI ou les bibliothèques clientes exploitent cette API.

### 2.6.3. Langages et bibliothèques InfluxDB

Ci-dessous, le tableau résumant les langages de développement fournissant des bibliothèques pour inter-opérer avec InfluxDB:

*Table 2. Tableau des langages*

| langags    |                      |        |       |         |               |
|------------|----------------------|--------|-------|---------|---------------|
| .Net       | Clojure              | Erlang | Go    | Haskell | Java          |
| JavaScript | JavaScript (Node.js) | Lisp   | Perl  | PHP     | <i>Python</i> |
| R          | Ruby                 | Rust   | Scala |         |               |

## 2.6.4. La "stack TICK"

InfluxDB propose également une suite logicielle "compagnon", composée de 4 éléments remplissant des fonctionnalités complémentaires à InfluxDB.

Elle sera décrite en [annexe](#) car finalement peu ou pas utilisée dans cette étude, ce qui sera d'ailleurs justifié lorsque l'on abordera le choix sur la méthode d'import de données.

## 2.6.5. Clients IHM

Le client d'administration web embarqué est [déprécié](#) depuis la 1.1, absent depuis la 1.3 au profit de Chronograf, qui est décrit plus loin.

Il existe aussi un [IDE](#) sous Windows, en bêta, non testé dans cette étude.

# 2.7. Le modèle de données d'InfluxDB

On verra dans cette partie les spécificités de la représentation de la donnée dans InfluxDB.

La ligne de la table, appelée "**point**" dans InfluxDB, suit la grammaire du "Line Protocol" que l'on résumera ci dessous.

*Une ligne de la table nommée "point"*

```
<measurement>[,<tag-key>=<tag-value>...] <field-key>=<field-value>[,<field2-key>=<field2-value>...] [unix-nano-timestamp]
```

Les [détails du line protocol](#) ainsi qu'un [tutorial sur le line protocol](#) sont dans la documentation officielle.

Dans les chapitres suivants, on décrira les types d'éléments constitutifs du point respectant le Line Protocol mentionnés ci dessus.

## 2.7.1. Premier élément : les "measurements" ou mesures

La mesure ou "measurement" est la table d'InfluxDB : Elle joue le rôle de container colonnes des tags, "fields" et "timestamps".

## 2.7.2. Second élément "optionnel" : les "tags"

Les *tags* sont les métadonnées et à ce titre leurs valeurs sont indexées. InfluxDB distingue *tag key* le nom de la colonne, de *tag value*, sa valeur. Leur type est contraint aux chaines de caractères.

Les tags sont optionnels mais importants car c'est sur eux que vont porter les critères des requêtes.

Pour simplifier, on parlera de tag pour designer le couple (tag key, tag, value).

### 2.7.3. Troisième élément : les "fields" ou champs

Ce sont les données contenues dans InfluxDB. Elles sont donc à ce titre obligatoires. Par contre, elles ne sont pas indexées. En cas de requête, le moteur scannerait toute la mesure !

Les valeurs des fields sont typées et peuvent être :

- \* des chaînes de caractères
- \* des entiers, avec un suffixe pour indiquer ce type (10i)
- \* des nombres réels
- \* des booléens sans sensibilité à la casse pour la syntaxe (true, FALSE...)

Pour simplifier, on parlera de field ou champ pour désigner le couple (field key, field, value).

### 2.7.4. Dernier mais non le moindre : le "timestamp" ou estampille

Par défaut, le timestamp est indiqué en nombre de nanosecondes écoulées depuis le 01/01/1970.

Sans mention de la date dans une insertion, c'est la date courante qui sera fournie.

Lors d'une requête, sans contrainte sur la valeur de time, les données retournées seront comprises entre 1/1/70 et l'instant de la requête.

A dire vrai, si ce format est adapté à des capteurs, à l'utilisation lors de tests unitaires humains, c'est un peu ennuyant.

Mais le CLI et l'API Influx DB permettent de donner une précision plus confortable. On verra comment par la suite.

Par contre, seule l'API **permet d'insérer un timestamp avec un format de date particulier...**

### 2.7.5. La "retention policy"

Trois points concernant ce paramètre important pour la fiabilité des données:

1. Dans la retention policy d'InfluxDB, on trouvera naturellement la durée de conservation des données. Cette partie sera reprise dans le chapitre administration.
2. Dans le contexte d'un cluster, on aura aussi les paramètres de réplication, c'est à dire sur combien de noeuds les "shard" seront répliqués. (Se référer au chapitre [clustering](#) pour un approfondissement du sujet)
3. Enfin l'objet retention policy comprend également le paramètre "Shard group duration" qui stipule l'intervalle de temps dont est responsable un shard group. Autrement dit et par exemple, un shard group distinct sera créé tous les 7 jours par défaut pour contenir les mesures liées à cet intervalle de temps. C'est un mode de fonctionnement propre à InfluxDB.

Par défaut, InfluxDB crée une RP nommée '*autogen*' dont les caractéristiques sont les suivantes :

- Rétention : durée infinie
- Facteur de réplication = 1
- "Shard Group duration" d'une semaine

On pourra obtenir plus d'informations dans la documentation sur [les retention policy](#).

## 2.7.6. Les Séries

Une série est une collection de données qui a en commun :

- la mesure
- le ou les mêmes valeurs de tags
- la politique de rétention

Les points qui ont les mêmes tags dans une même mesure appartiennent à la même série de points.

point is uniquely identified by the measurement name, tag set, and timestamp. If you submit Line Protocol with the same measurement, tag set, and timestamp, but with a different field set, the field set becomes the union of the old field set and the new field set, where any conflicts favor the new field set.

## 2.7.7. Les bonnes pratiques sur la création de schémas

Les [bonnes pratiques sur la création de schémas InfluxDB](#) sont décrites dans la documentation.

On en retiendra quelques éléments :

- Les tags ne doivent pas avoir trop de modalités sous peine d'une consommation excessive de mémoire.

### IMPORTANT

C'est un écueil que l'on a expérimenté lors des tests en fixant comme tag la température ou la pression. La quantité de mémoire consommée par InfluxDB devient telle que la machine de tests devient inutilisable (swap)...

- On choisit un type tag à une variable à laquelle on veut appliquer un GROUPBY.
- On choisit un type "field" à une variable à laquelle on veut appliquer une fonction influxQL.

## 2.8. Le langage d'interrogation d'InfluxDB : InfluxQL (ou IQL)

InfluxDB propose un langage de requête complet qui ressemble au SQL, dénommé InfluxQL que l'on abrègera par IQL par la suite.

La documentation référence d'influxQL est [ici](#).

### 2.8.1. Un langage de requêtes à priori similaire au SQL...

On retrouve les mnémoniques et qualifieurs classiques et des originalités :

- *INSERT*

- *SELECT*
- *WHERE*
- *GROUP BY*
- *INTO* qui permet de stocker les résultats d'une requête dans une autre base; cela peut être utilisé dans le [chapitre continuous query](#).
- *LIMIT*
- *OFFSET*
- *ORDER BY*
- *DESC / ASC*
- *AS*
- *FILL* permet de retourner une valeur par défaut pour un intervalle vide résultant d'une requête de groupBy.

On peut également effectuer des *calculs* sur les fields et des *expressions régulières* sur les tags. (cf exemples infra)

On ne décrira pas ici le fonctionnement de chacune de ces instructions. Le lecteur avec une expérience du SQL se rendra immédiatement compte des fonctions. Pour les autres, des exemples d'utilisation seront présentés dans le chapitre approfondissement.

Par contre, on ne trouve ni UPDATE, ni DELETE.

### 2.8.2. ... mais CR-ud pas CRUD ...

Si jusque là, InfluxDB possède de nombreuses caractéristiques d'un SGBD relationnel classique, il s'en distingue car il ne comporte pas d'UPDATE et qu'un DELETE au comportement spécifique existe.

"written once, rarely updated"

La signification des données est rarement unitaire mais prend son sens sur un large groupe de mesures (les times series)

Par conséquent, InfluxDB privilégie la création et les requêtes sur la mise à jour et la destruction; le tout pour focaliser sur la performance des 2 premiers critères. La [documentation](#) résume cela par CR-ud au lieu de CRUD pour les SGBDR SQL.

Il faut donc utiliser des contournements pour faire des opérations de mise à jour :

- Pour mettre à jour un point, il faut l'insérer à nouveau avec le même ensemble measurement, tag(s) et timestamp.
- On peut supprimer une série mais pas directement des points. Le contournement consistant à trouver le timestamp d'une valeur de "field" donnée et le supprimer.

### 2.8.3. ...et sans jointure

Pour des [raisons](#) liées au domaine des TSDB, au choix de conception et à la performance, IQL ne propose pas de jointure, comme expliqué dans le lien précédent.

Par contre InfluxData semble proposer un nouveau langage, **IFQL**, pour un plan de requête moins coûteux et pour pouvoir exprimer ces requêtes "select-project-join" puissantes, mais complexes.

### 2.8.4. Les fonctions IQL

IQL propose 4 familles de fonctions, riches, très bien décrites [dans la documentation](#).

On propose des [tableaux de synthèse](#) des fonctions IQL en annexe.

## 2.9. Protocoles et formats

Outre le "LineProtocol" sur TCP, InfluxDb est également compatible avec les protocoles suivants :

- CollectD  
Le format est celui de collectd, le protocole transport est UDP.
- Graphite  
Grâce à un plugin, Influx accepte le format Graphite.
- OpenTSDB  
InfluxDB supporte les protocoles telnet and HTTP d'OpenTSDB. InfluxDB peut donc remplacer OpenTSDB !
- Prometheus  
InfluxDB fournit l'API Prometheus pour la lecture et l'écriture par un processus de conversion en format InfluxDB.



## 3. Utilisation superficielle

L'objectif de ce chapitre est d'illustrer ce que l'on peut faire avec InfluxDB concrètement, sachant les informations théoriques du chapitre précédent.

On va tout d'abord travailler avec un jeu de données minimal, un sous-ensemble de données physiques (température, pression), l'exploitation en profondeur avec des données météo plus complètes étant dédiée à un [chapitre ultérieur](#).

La partie Installation et paramétrage est reportée en [annexe](#) car non nécessaire à la compréhension de la suite du document. Le lecteur souhaitant mettre en place un environnement de tests pourra s'y reporter.

### 3.1. Création (C)

Dans ce chapitre, on explore les capacités de création d'objets InfluxDB.

#### 3.1.1. Base

*Création par CLI d'une base*

```
> create database test_mesures
> show databases
name: databases
name
---
_internal
test_mesures
```

*Alternative : Création par API REST*

```
user@M40474:~$ curl -i -XPOST http://localhost:8086/query --data-urlencode "q=create
database test_mesures_REST"
HTTP/1.1 200 OK
Content-Type: application/json
Request-Id: a1367134-0803-11e8-8175-000000000000
X-Influxdb-Build: OSS
X-Influxdb-Version: 1.5.2
X-Request-Id: a1367134-0803-11e8-8175-000000000000
Date: Fri, 02 Feb 2018 10:27:11 GMT
Transfer-Encoding: chunked

{"results":[{"statement_id":0}]}
```

Chaque commande CLI a son équivalent API. On donnera des exemples CLI exclusivement à partir de ce point.

### 3.1.2. "measurements" ou tables

La table est créée à la première insertion en suivant la grammaire "line Protocol". Il n'a pas de commande au sens propre pour en créer.

### 3.1.3. Insertion

Dans cette partie, on va voir les différentes façons de (bien) insérer des "tags", "fields" et éventuellement timestamp dans un "measurement".

*Ligne par ligne par CLI (avec la politique de rétention par défaut)*

```
> USE test_mesures
Using database test_mesures
> INSERT mesure_station,id_station=zzzz,altitude_station=500i
temperature=15,pression=1.0 1421100000000000
SELECT * FROM mesure_station WHERE id_station=='zzzz'
> SELECT * FROM mesure_station WHERE id_station='zzzz'
```

| name: mesure_station |                  |            |          |             |
|----------------------|------------------|------------|----------|-------------|
| time                 | altitude_station | id_station | pression | temperature |
| ----                 | -----            | -----      | -----    | -----       |
| 1421100000000000     | 500i             | zzzz       | 1        | 15          |

*Ligne par ligne par API REST*

```
curl -XPOST 'http://localhost:8086/write?db=test_mesures' \
--data-binary 'mesure_station,id_station=xxxx,altitude_station=200i
temperature=20,pression=1.2 1421000000000000'
```

*En batch*

Pour insérer massivement des données, le [CLI avec option -import](#) permet de le faire pour peu que l'on se plie au Line protocol InfluxDB.

*un exemple tiré de la documentation*

```
# DDL
CREATE DATABASE pirates
CREATE RETENTION POLICY oneday ON pirates DURATION 1d REPLICATION 1

# DML
# CONTEXT-DATABASE: pirates
# CONTEXT-RETENTION-POLICY: oneday

treasures,captain_id=dread_pirate_roberts value=801 1439856000
treasures,captain_id=flint value=29 1439856000
treasures,captain_id=sparrow value=38 1439856000
treasures,captain_id=tetra value=47 1439856000
treasures,captain_id=crunch value=109 1439858880
```

**DDL** signifiant Data definition language, la partie dédiée à la création des database et des politiques de rétention.

**DML** signifiant Data Manipulation Language, partie qui sélectionne Database et Politique de rétention puis insère les points.

Une alternative pour des données "brutes" consiste à utiliser Telegraf, plus aisée si l'on ne veut pas faire de développement, mais contrainte sur les formats de données, comme on le verra plus tard.

## 3.2. Interrogation (R)

### 3.2.1. Lister les bases

```
> show databases
name: databases
name
---
_internal
```

\_internal contient les métadonnées internes et les données de profiling.

### 3.2.2. Informations sur les "measurements" et ses colonnes

*Pour afficher les mesures*

```
> use test_mesures
Using database test_mesures
> show measurements
name: measurements
name
---
measure_station
```

*Lister les "fields"*

```
> SHOW FIELD KEYS
name: measure_station
fieldKey    fieldType
-----
pression    float
temperature float
```

### Lister les tags

```
> SHOW TAG KEYS
name: mesure_station
tagKey
-----
altitude_station
id_station
```

### Lister les séries

```
> show series
key
---
mesure_station,altitude_station=200i,id_station=xxxx
```

## 3.2.3. Interrogations "classiques"

### Lister tout le contenu de la mesure "mesure\_station"

```
> select * from mesure_station
name: mesure_station
time          altitude_station id_station pression temperature
-----
1421000000000000 200i          xxxx          1.2          20
```

### La même chose en spécifiant directement database, retention policy et measurement

```
> SELECT * FROM "test_mesures"."autogen"."test_mesures"
name: test_mesures
time          altitude_station id_station pression temperature
-----
2018-02-03T17:21:54.574244521Z 2000i          yyyy          0.8          30
```

Le format de la date est également plus lisible.

### Filtrer une valeur ... en parcourant toute la mesure

```
>select * from mesure_station where temperature < 50
name: mesure_station
time          altitude_station id_station pression temperature
-----
1421000000000000 200i          xxxx          1.2          20
```

Filtrer une valeur en utilisant un tag donc un index

```
>select * from mesure_station where id_station = 'xxxx'
name: mesure_station
time            altitude_station id_station pression temperature
-----
1421000000000000 200i            xxxx            1.2            20
```

#### IMPORTANT

Utiliser la syntaxe suivante pour avoir des dates lisibles par un être humain.

```
>precision rfc3339
>select * from mesure_station where id_station = 'xxxx'
name: mesure_station
time            altitude_station id_station pression temperature
-----
1970-01-17T10:43:20Z 200i            xxxx            1.2            20
```

### 3.3. Mises à jour (U)

Comme déjà expliqué, la mise à jour et la suppression ont un comportement spécifique dans InfluxDB.

Un point est identifié de manière unique par son "measurement", l'ensemble de ses tags et son estampille.

D'après la documentation et après expérimentation, le [résultat de la "mise à jour" d'un point](#), c'est à dire l'insertion d'un point avec les mêmes identifiants uniques résultera par l'\*union\* des deux points, le plus récent prenant le pas avec ses valeurs le cas échéant.

*Un exemple illustrant la mise à jour adaptée de la documentation officielle*

```
> INSERT mesure_station,id_station=zzzz,altitude_station=500i temperature=15

> select * from mesure_station where time = 1525808295545544168
name: mesure_station
time            altitude_station id_station pression temperature
-----
1525808295545544168 500i            zzzz            15
```

On remarque que la valeur de pression n'est pas renseignée.

*insertion du "même" point avec un field supplémentaire*

```
> INSERT mesure_station,id_station=zzzz,altitude_station=500i
temperature=15,pression=1.0 1525808295545544168
```

le point "union" résultant

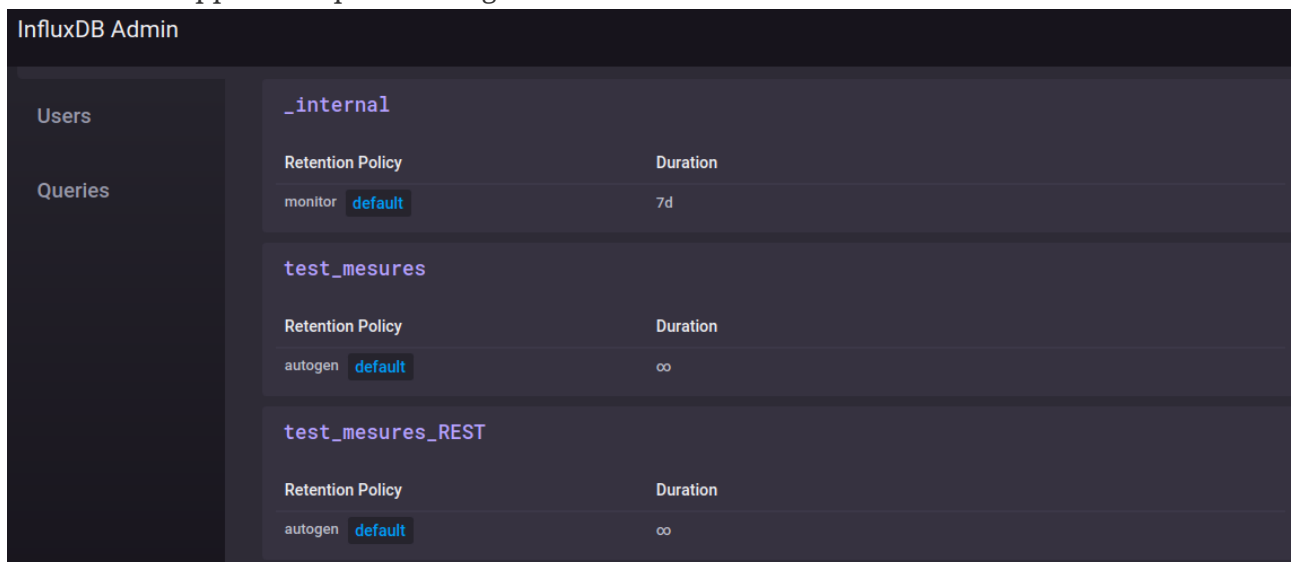
```
> select * from mesure_station where time = 1525808295545544168
name: mesure_station
time                altitude_station id_station pression temperature
-----
1525808295545544168 500i                zzzz          1          15
```

## 3.4. Suppression... (D)

InfluxDB permet de supprimer, via des commandes d'administration, un ensemble de points :

### 3.4.1. ...de bases

- Suppression de base `DROP DATABASE <database_name>`
- Alternative suppression par chronograf



### 3.4.2. ...de séries

C'est la manière de supprimer ses essais /erreurs :

- Suppression de séries `DROP SERIES FROM <measurement_name[,measurement_name]> WHERE <tag_key>='<tag_value>'`

exemple :

```

> select * from synop
name: synop
time      -10      -520      -60      -666666 0      0.000000 0.200000 07005
101620 102510 170 19290 2.000000 2.900000 20171101000000 278.050000 280.050000
281.550000 3.200000 7 87
----
-----
-----
1525937705274858290 -10      -510      -60      -666666 0      0      -0.1      7015
101890 102470 190 11470 3.6      4.4      20171101000000 278.25      279.95
279.75      5.1      7 89
...
1525937705494431967 -10      -666666 -160 -666666 21      -666666 -666666 7460 98050
101940 100 10000 1      -666666 20040601000000 285.35      285.95      -666666
2.1      6 96
> DROP SERIES FROM synop
> SELECT * FROM synop

```

Une alternative :

- suppression des points de la série contrairement à précédemment:
  - sans supprimer la série de l'index
  - supporte le where sur le timestamp

```
DELETE FROM <measurement_name> WHERE [<tag_key>='<tag_value>'] | [<time interval>]
```

### 3.4.3. ...de "measurements"

Suppression de tables `DROP MEASUREMENT <measurement_name>`

### 3.4.4. Et les points ?

Par contre, il est impossible de supprimer un point autrement que par une politique de rétention.

#### TIP

Il existe un contournement mentionné par la [documentation](#) qui consiste à rechercher la valeur du field, puis le timestamp correspondant puis effectuer un DELETE fondé sur le timestamp.

## 4. Approfondissement et fonctionnalités SGBD pour une problématique de données massives

### 4.1. La problématique de données "massives"

Ayant étudié principalement des données catégorielles en STA211, et pour préparer InfluxDB à une utilisation "massive", on s'est fixé quelques objectifs :

- Traiter un sujet ayant trait à des mesures physiques
- Que ces mesures puissent être importantes en terme de variables et d'individus
- Que le sujet produise des mesures compatibles avec InfluxDB...

Après quelques échanges lors des jalons NFE204, le visionnage des arrière-plans des vidéos de ce cours et la mine rejouie des enseignants STA211 lors de leurs déplacements, l'objectif d'une étude météorologique et, en particulier, de la météo de communes plus méridionales que Paris comme Nice, s'est imposé.

### 4.2. Choix des données

Le site de Météofrance fournit des données publiques, gratuites et librement utilisables pour peu, d'après la licence d'utilisation que l'on mentionne sa [source et paternité](#) ... ce qui est chose faite conformément aux instructions du lien précédent dans la rubrique "Condition d'accès".

Ces données contiennent des informations intelligibles au profane de la météorologie: température, pression, lieu de mesure, vitesse du vent, enneigement...

*Descriptif des données choisies issu du site de meteoFrance*

Données d'observations issues des messages internationaux d'observation en surface (SYNOP) circulant sur le système mondial de télécommunication (SMT) de l'Organisation Météorologique Mondiale (OMM). Paramètres atmosphériques mesurés (température, humidité, direction et force du vent, pression atmosphérique, hauteur de précipitations) ou observés (temps sensible, description des nuages, visibilité) depuis la surface terrestre. Selon instrumentation et spécificités locales, d'autres paramètres peuvent être disponibles (hauteur de neige, état du sol, etc.)

Nous découvrons ainsi une [émanation des Nations Unies](#), impliquée dans les problématiques écologiques actuelles, et ses moyens techniques de partage de mesures météorologiques.

Quelques caractéristiques des données SYNOP mises à disposition [dans les diverses rubriques de la page leur étant dédiée](#):

- 1 fichier par mois
- données qui couvrent du 1/1996 au 11/2017 donc 22 ans



- 1 mois = 14000 lignes en moyenne donc près de 4M de lignes
- format CSV
- fréquence de production d'un point par station : toutes les 3h

En [\[annexe\\_SYNOP\]](#), le tableau décrivant les mnémoniques des colonnes du fichier CSV, leur types et unités :

Ci-après, un aperçu de quelques colonnes :

| numer_<br>sta | date               | pmer   | tend | cod_tend | dd  | ff            | t              | td             | u  |
|---------------|--------------------|--------|------|----------|-----|---------------|----------------|----------------|----|
| 7005          | 2017050<br>1000000 | 100160 | 60   | 0        | 150 | 2.700000      | 282.4500<br>00 | 280.8500<br>00 | 90 |
| 7015          | 2017050<br>1000000 | 100270 | 190  | 2        | 200 | 4.600000      | 283.4500<br>00 | 281.8500<br>00 | 90 |
| 61996         | 2017050<br>1030000 | 100890 | -80  | 5        | 300 | 12.30000<br>0 | 290.3500<br>00 | 286.0500<br>00 | 76 |
| 61997         | 2017050<br>1030000 | 101850 | -120 | 8        | 240 | 15.40000<br>0 | 276.6500<br>00 | 275.1500<br>00 | 90 |
| 7181          | 2017050<br>1060000 | 101190 | 210  | 3        | 190 | 5.200000      | 279.6500<br>00 | 278.4500<br>00 | 92 |
| 7190          | 2017050<br>1060000 | 101210 | 390  | 3        | 270 | 3.000000      | 280.9500<br>00 | 277.8500<br>00 | 81 |
| 7335          | 2017050<br>6120000 | 101210 | 160  | 3        | 240 | 9.600000      | 287.8500<br>00 | 282.8500<br>00 | 72 |
| 7434          | 2017050<br>6120000 | 101350 | 190  | 1        | 250 | 6.100000      | 285.7500<br>00 | 281.4500<br>00 | 75 |

On trouvera en [annexe](#) ou dans [la rubrique information sur les stations du site dédié aux données](#) les diverses correspondances entre codes numer\_sta et noms de villes, paramètres géodésiques et altitude

## 4.3. Récupération des données

Les données sont disponibles sur le site internet de MétéoFrance via un formulaire.

Après une rapide analyse du fonctionnement de ce formulaire, on développe un script pour récupérer l'ensemble des données en une passe pour constituer un jeu conséquent.

Ce code du script [de récupération des données meteo france](#) est fourni en annexe.

## 4.4. Préparation des données

Après exploration des données, on découvre que les valeurs manquantes sont marquées 'mq', ce qui est facile pour les distinguer de données numériques.

InfluxDB acceptant les valeurs manquantes, une amélioration du script d'import décrit ci-après permettra de résoudre ce problème.

Par contre, le choix est d'ignorer les lignes où *tous les champs valent mq*, car InfluxDB impose au moins un "field" non vide.

## 4.5. Les choix de modélisation

Une fois les données choisies et découvertes, se pose la question de leur représentation dans InfluxDB : Quelle variable indexer? Que considérer comme "field" ?

On décide que seuls l'horodatage et le code de la station de mesure nous permettront d'obtenir les données météo utiles (température, pression, vent, humidité...). Ces dernières seront considérées comme des "field".

En effet, et l'on découvre une caractéristique importante d'InfluxDB, on ne peut pas obtenir dans un `SELECT` les "tags values" sans préciser un "field".

Par exemple, la requête `SELECT numer_sta FROM synop ...` ne renvoie aucune valeur !

Par contre, `SELECT temperature,numer_sta FROM synop` renverra bien les informations espérées (en [annexe](#), les références à cette "découverte").

Manifestement, la question est sujette à débats récents [ici](#) et surtout [là](#)

## 4.6. Quel outil choisir pour importer ?

Une fois le schéma choisi, il faut maintenant importer les données. Pour ce faire, plusieurs solutions se présentent. La suite de ce chapitre éclairera le lecteur sur le choix effectué.

### 4.6.1. Logstash

Logstash est un outil d'import transformation et export de données, composant de la suite compagnon d'ElasticSearch, versatile car fondé sur de multiples plugins...et déjà connu de l'auteur ! C'est donc naturellement la première solution qui émerge, d'autant que la documentation de [Telegraph référence Logstash](#) comme exemple de son parseur Grok.

On imagine alors une solution du type "plugin input file" plus un "filter csv" combiné avec le plugin "output influxdb"...mais l'objectif étant de découvrir InfluxDB et son environnement, si l'on doit utiliser un ETL autant utiliser la stack TICK (et ainsi avoir la bonne stack TICK...) .

### 4.6.2. Telegraf

On se tourne donc vers [Telegraf](#), décrit en annexe.

La configuration par défaut, utilisable immédiatement, permet la capture d'un nombre impressionnant de métriques, du système d'exploitation ou d'outils classiques.

Néanmoins, [le format CSV n'est pas supporté directement](#) et ce, même si CSV est un format répandu et que [la demande d'évolution a été faite](#) auprès d'InfluxData.

C'est regrettable car JSON est supporté nativement dans InfluxDB ... mais les données ne sont pas en JSON !

On a trouvé a posteriori les mêmes [données météo en JSON](#) mais sur un site tiers : Faute de temps pour accréditer ces données, on préférera l'original à la copie.

### 4.6.3. API InfluxDB par bibliothèque Python

Plutôt que se contraindre à étudier une configuration et l'adapter hypothétiquement à son besoin, on s'oriente vers le développement d'un script autour de la bibliothèque Python InfluxDB. Si c'est une approche qui s'adaptera au besoin, elle peut consommer du temps de mise au point.

Pour ne pas réinventer la roue, on évalue des codes disponibles sur Internet. Si le [premier essai](#) est infructueux, le [second](#) aboutit moyennant quelques modifications.

On choisit d'importer l'ensemble des données. On rappelle la répartition des colonnes de la table :

- \* Estampille
- \* Un unique tab (numer\_sta)
- \* 57 fields

On va importer 22 ans de données (de 1996 à 2017), c'est à dire 264 mois soit, si un mois contient approximativement 15000 lignes, **4 millions de lignes**.

#### WARNING

Quand tous les "fields values" sont manquantes, on a le message d'erreur suivant à l'import. Le "point" sera simplement ignoré.

*Message d'erreur "lignes sans fields"*

```
influxdb.exceptions.InfluxDBClientError: 400: {"error": "partial write: unable to parse 'synop,numer_sta=81415,pres=0,t=304.850000 1487689200000000000': invalid field format dropped=0"}
```

*Import des données météo dans un conteneur InfluxDB*

```
21:08:30-user@M40474:~/Bureau/CNAM/git/CNAM-projets/NFE204(master)$ for i in
donnees/extractions/*.csv;do python3 ../../csv-to-influxdb/csv-to-influxdb.py -d';' -s
'172.17.0.2:8086' -m 'synop' -tc 'date' -tf '%Y%m%d%H%M%S' --fieldcolumns
pmer,tend,dd,ff,td,u,vv,hbas,tnN,txN,rafper,pres,t,cod_tend,td,vv,ww,w1,w2,n,nbas,cl,c
m,ch,niv_bar,geop,tend24,tn12,tn24,tx12,tx24,tminsol,sw,tw,raf10,rafper,per,etat_sol,h
t_neige,ssfrai,perssfrai,rr1,rr3,rr6,rr12,rr24,phenspe1,phenspe2,phenspe3,phenspe4,nnu
age1,ctype1,hnuage1,nnuage2,ctype2,hnuage2,nnuage3,ctype3,hnuage3,nnuage4,ctype4,hnuag
e4 --tagcolumns numer_sta --dbname meteo --input $i;done
Read 5000 lines
Inserting 5000 datapoints...
Wrote 5000, response: True
Read 10000 lines
...
```

### Les 59 champs importés

```
> SHOW FIELD KEYS FROM synop
name: synop
fieldKey fieldType
-----
ch        float
cl        float
...
w1        float
w2        float
ww        float
```

## La récupération de lignes

[illegible]

## WARNING

On constate dès cette première requête de test...une augmentation importante (2Go) de la mémoire occupée par le container InfluxDB

Nombre de lignes insérées

```
> SELECT COUNT(*) FROM synop
+++
```

**IMPORTANT**

La commande fait swapper la machine et elle devient inutilisable.

**TIP**

Pour tuer une requête longue, cf [deux solutions](#): par le CLI **KILL QUERY** ou simplement **CTRL+C**

## 4.7. Résoudre les problèmes d'import

### 4.7.1. Réduire le nombre de points

Après une lecture de la documentation des [paramètres InfluxDB](#), on décide de :

- ⇒ stopper la base de surveillance `_internal`
- ⇒ modifier la configuration du cache pour lancer la serialisation sur disque plus souvent (10m à 1m)
- ⇒ baisser la valeur maximale du cache
- ⇒ réduire la mémoire occupée par le cache de l'index

...et réduire la quantité de données...

### 4.7.2. Réduire le nombre de fields

On finit par choisir de limiter le nombre de colonnes pour pouvoir importer plus d'individus sur l'infrastructure de tests.

*Enumération des colonnes*

```
> SHOW FIELD KEYS
name: synop
fieldKey fieldType
-----
dd        float
ff        float
hbas      float
pmer      float
pres      float
rafper    float
t         float
td        float
tend      float
u         float
vv        float
```

### Import d'un sous-ensemble des colonnes (13) sur l'intégralité des individus

```
21:57:11-user@M40474:~/Bureau/CNAM/git/CNAM-projets/NFE204(master)$ for i in
donnees/extractions/*.csv;do python3 ../../csv-to-influxdb/csv-to-influxdb.py -d';' -s
'172.17.0.2:8086' -m 'synop' -tc 'date' -tf '%Y%m%d%H%M%S' --fieldcolumns
pmer,tend,dd,ff,td,u,vv,hbas,tnN,txN,rafter,pres,t --tagcolumns numer_sta --dbname
meteo --input $i;done
Read 5000 lines
Inserting 5000 datapoints...
Wrote 5000, response: True
Read 10000 lines
...
```

### Récupération de quelques lignes

```
> SELECT * FROM synop LIMIT 5
name: synop
time                dd  ff  hbas numer_sta pmer  pres  rafter t      td      tend u
vv
----
--
1996-01-01T00:00:00Z 170 2      07005      100030 99090      276.04 275.95 100  99
1996-01-01T00:00:00Z 100 2    2250 89642      98820  98290      271.15 261.65 10  44
40000
1996-01-01T00:00:00Z 0   0      07015      100020 99380      275.95 275.35 100  96
300
1996-01-01T00:00:00Z 120 4.1 250  07027      99940  99130      279.04 279.04 0   100
1200
1996-01-01T00:00:00Z 110 1   70   07130      99900  99380      281.25 280.65 -10  96
800
```

### Comptage des lignes

```
> SELECT COUNT(*) FROM synop
name: synop
time                count_dd count_ff count_hbas count_pmer count_pres count_rafter
count_t count_td count_tend count_u count_vv
----
-----
1970-01-01T00:00:00Z 3323727 3324681 1998697 3252545 2891372 1776188
3380581 3366987 2840858 3365351 2479722
```

Il semble que ce sous-ensemble de donnée soit utilisable dans le contexte de l'infrastructure de tests mis à disposition.

Avant de tirer des informations des données, on interroge InfluxDB sur sa manière de les stocker.

Si InfluxDB partitionne les données en shards comme de nombreux SGBD NOSQL, une originalité est qu'InfluxDB les regroupe en groupes d'intervalles de temps finis.

## Constater le regroupement de shards par intervalles de temps : les "shard groups"

```
> SHOW SHARDS
...
name: meteo
id  database retention_policy shard_group start_time          end_time
expiry_time      owners
--  -
-----
3021 meteo    autogen          3021          1996-01-01T00:00:00Z 1996-01-08T00:00:00Z
1996-01-08T00:00:00Z
3022 meteo    autogen          3022          1996-01-08T00:00:00Z 1996-01-15T00:00:00Z
1996-01-15T00:00:00Z
...
4109 meteo    autogen          4109          2017-12-18T00:00:00Z 2017-12-25T00:00:00Z
2017-12-25T00:00:00Z
4110 meteo    autogen          4110          2017-12-25T00:00:00Z 2018-01-01T00:00:00Z
2018-01-01T00:00:00Z
```

Par contre, il ne faut pas [se fier à la colonne expiry\\_time](#), les données de 1996 étant fort heureusement toujours disponibles :

Requêter les données antérieures à 1997

```
> SELECT * FROM synop WHERE time < '1997-01-01'
name: synop
time          dd ff  hbas numer_sta pmer  pres  t    td    tend  u    vv
-----
1996-01-01T00:00:00Z 170 2    07005 100030 99090 276.04 275.95 100 99
1996-01-01T00:00:00Z 100 2    2250 89642 98820 98290 271.15 261.65 10 44
40000
...
```

On peut aller plus loin avec des commandes telles que [influx\\_inspect](#).

La commande `SHOW STATS` nous donne entre autres l'occupation mémoire :

```
name: runtime
Alloc      Frees      HeapAlloc HeapIdle  HeapInUse HeapObjects HeapReleased HeapSys
Lookups Mallocs      NumGC NumGoroutine PauseTotalNs Sys      TotalAlloc
-----
110615032 206060142 110615032 1774403584 190300160 366717      1599184896 1964703744
86306 206426859 166 17      110406088 2078956024 17800933456
...
```

### Le nombre de requêtes et leur temps d'exécution

```
...
name: queryExecutor
queriesActive queriesExecuted queriesFinished queryDurationNs recoveredPanics
-----
1 13 12 14139604864 0
...
```

### Le nombre de séries dans la base météo

```
...
name: database
tags: database=meteo
numMeasurements numSeries
-----
1 62
...
```

Et ce qui explique la consommation mémoire:

### Le cache par shard

```
...
name: shard
tags: database=meteo, engine=tsm1, id=3021,
path=/var/lib/influxdb/data/meteo/autogen/3021, retentionPolicy=autogen,
walPath=/var/lib/influxdb/wal/meteo/autogen/3021
diskBytes fieldsCreate seriesCreate writeBytes writePointsDropped writePointsErr
writePointsOk writeReq writeReqErr writeReqOk
-----
145804 27913 59 0 0 0 3090
1 0 1
...

name: tsm1_cache
tags: database=meteo, engine=tsm1, id=3021,
path=/var/lib/influxdb/data/meteo/autogen/3021, retentionPolicy=autogen,
walPath=/var/lib/influxdb/wal/meteo/autogen/3021
WALCompactionTimeMs cacheAgeMs cachedBytes diskBytes memBytes snapshotCount
writeDropped writeErr writeOk
-----
25 996 462000 0 0 0 0
0 1
...
```



## 4.8. Traitement

On propose dans cette partie un certain nombre de requêtes qui permettront d'illustrer les fonctionnalités d'InfluxDB. Au fil de ces requêtes, on découvrira des informations sur la problématique des données météo.

Dans une étude de données complètes, ces informations fourniraient la base à une exploitation par des algorithmes de traitement de données massives et surtout une analyse plus approfondie; un exemple ambitieux pouvant être de produire un modèle de prédiction...

### 4.8.1. Quelques requêtes simples

*Décaler la sélection de points*

```
> SELECT * FROM synop LIMIT 3 OFFSET 15
name: synop
time                dd ff hbas numer_sta pmer pres rafper t      td
tend tnN txN u  vv
----
-----
2017-01-01T00:00:00Z 300 5.7 -999999 07661      102770 101120 9.6      281.750000 277.35
-100 0  0  74 -999999
2017-01-01T00:00:00Z 330 6.5 -999999 07690      102750 102420 8.2      279.150000 270.05
-130 0  0  52 50000
2017-01-01T00:00:00Z 0  0  30      07037      102830 100870 0        268.650000 267.65
-190 0  0  93 130
```

*Ordonner la sélection par critère chronologique décroissant*

```
> SELECT * FROM synop ORDER BY time DESC LIMIT 3
name: synop
time                dd ff hbas numer_sta pmer pres rafper t      td      tend u
vv
----
-----
--
2017-12-31T21:00:00Z 50  3.8      81415      101230 100020      298.45 295.95 10  86
2017-12-31T21:00:00Z 230 7.2      07005      100030 99160  22.2      280.85 277.45 120 79
20000
2017-12-31T21:00:00Z 0  0  450  81405      101220 101130 1.5      298.85 297.65 -30 93
28540
```

*Enumération en créant une colonne résultat*

```
> SELECT COUNT(pmer) AS nb FROM synop
name: synop
time                nb
----
--
1970-01-01T00:00:00Z 3252545
```

### Nombre de mesures de températures à Nice (07690)

```
> SELECT COUNT(t) FROM synop WHERE numer_sta = '07690'
name: synop
time                count
----                -
1970-01-01T00:00:00Z 58596
```

Donner la force du vent en m/s, sa direction en °, la vitesse des rafales en m/s, la pression au niveau de la mer en Pa à Nice à quelques heures de 2018

```
> SELECT dd,ff,rafter,pmer FROM synop WHERE time > '2017-12-31T00:00:00Z' AND
numer_sta = '07690'
name: synop
time                dd  ff  rafter pmer
----                --  --  -
2017-12-31T03:00:00Z 330 4   5.4   101880
2017-12-31T06:00:00Z 350 4.4 6.7   101950
2017-12-31T09:00:00Z 330 6.5 8.2   102070
2017-12-31T12:00:00Z 320 3   7.2   101980
2017-12-31T15:00:00Z 180 2.1 3.1   101810
2017-12-31T18:00:00Z 320 3.7 5.4   101750
2017-12-31T21:00:00Z 330 4.3 6.8   101670
```

Mêmes mesures quand la vitesse du vent moyen excède 72 km/s vitesse du vent

```
> SELECT numer_sta,dd,ff,rafter,pmer FROM synop WHERE ff > 20 LIMIT 5
name: synop
time                numer_sta dd  ff  rafter pmer
----                -
1996-01-10T00:00:00Z 07661   70  21   100790
1996-01-15T15:00:00Z 61998  270 22.1  100280
1996-01-18T12:00:00Z 61997  220 21.6  100320
1996-01-20T15:00:00Z 89642  180 25.2   97820
1996-01-20T15:00:00Z 61997  320 20.5   99660
```

#### IMPORTANT

La requête est beaucoup plus lente car le where porte sur un "field" ce qui implique un "full scan" du "measurement".

#### TIP

L'endroit de mesure est sans doute situé outremer, en tout cas ce code n'est pas référencé dans le [fichier de correspondance](#) fourni par MétéoFrance.

## 4.8.2. "Jouer" avec les "temps"

### *La température à Nice fin juin*

```
> SELECT t -273 FROM synop WHERE time > '2017-06-29T09:00:00Z' AND time < '2017-06-30' AND numer_sta = '07690'
name: synop
time            td      numer_sta
----            --      -
2017-06-29T12:00:00Z 288.55 61972
2017-06-29T15:00:00Z 288.35 61972
2017-06-29T18:00:00Z 289.15 61972
2017-06-29T21:00:00Z 289.15 61972
```

### *La température à Nice à 5h du jour de l'an 2018*

```
> SELECT td,numer_sta FROM synop WHERE time > '2017-12-31T09:00:00Z' - 5h AND
numer_sta = '07690'
name: synop
time            td      numer_sta
----            --      -
2017-12-31T06:00:00Z 277.15 07690
2017-12-31T09:00:00Z 276.95 07690
2017-12-31T12:00:00Z 278.75 07690
2017-12-31T15:00:00Z 281.25 07690
2017-12-31T18:00:00Z 278.55 07690
2017-12-31T21:00:00Z 278.25 07690
```

### *La température de rosée à Nice le jour de la naissance de mon fils après 7h, 133m et 1456 secondes*

```
> SELECT td,numer_sta FROM synop WHERE time > '2011-05-15' +7h + 133m +1456s AND
numer_sta = '07690' LIMIT 3
name: synop
time            td      numer_sta
----            --      -
2011-05-15T12:00:00Z 284.05 07690
2011-05-15T15:00:00Z 282.25 07690
2011-05-15T18:00:00Z 281.35 07690
```

### *En Martinique l'humidité en % autour du 28/05/2017 à 3h*

```
> SELECT numer_sta,u FROM synop WHERE numer_sta =~ /78.../ AND time = '2017-05-28' +
3h
name: synop
time            numer_sta u
----            -
2017-05-28T03:00:00Z 78897 93
2017-05-28T03:00:00Z 78922 87
2017-05-28T03:00:00Z 78925 81
```

### 4.8.3. Agrégations

*Humidité moyenne à Nice en février 2017*

```
> SELECT MEAN(u) FROM synop WHERE time > '2017-02-01' AND time < '2017-02-28' AND
numer_sta = '07690'
name: synop
time                                mean
----                                ----
2017-02-01T00:00:00.000000001Z 72.57309941520468
> SELECT MEAN(u) FROM synop WHERE time > '2017-02-01' AND time < '2017-02-28' AND
numer_sta = '07690'
```

*Humidité moyenne en % par station*

```
> SELECT MEAN(u) FROM synop GROUP BY numer_sta
name: synop
tags: numer_sta=07005
time                                mean
----                                ----
1970-01-01T00:00:00Z 82.10907789818033

name: synop
tags: numer_sta=07015
time                                mean
----                                ----
1970-01-01T00:00:00Z 79.44397775774993
...
```

*Hauteur des nuages moyenne à Nice par semaine entre avril et mai*

```
> SELECT MEAN(hbas) FROM synop WHERE numer_sta = '07690' AND time >= '2017-04-
06T00:00:00Z' AND time <= '2017-05-06T00:00:00Z' GROUP BY time(7d)
name: synop
time                                mean
----                                ----
2017-04-06T00:00:00Z 772.5
2017-04-13T00:00:00Z 719.2307692307693
2017-04-20T00:00:00Z 611.1111111111111
2017-04-27T00:00:00Z 1057.4285714285713
2017-05-04T00:00:00Z 855
```

### 4.8.4. Fonctions de sélection

#### *Les 5 températures les plus chaudes en °C à Nice pendant l'été 2017*

```
> SELECT TOP(t,5)-273 FROM synop WHERE numer_sta = '07690' AND time >= '2017-06-01'
AND time <= '2017-09-01'
name: synop
time                top
----              ---
2017-06-17T15:00:00Z 30.25
2017-06-17T18:00:00Z 29.949999999999999
2017-07-24T12:00:00Z 34.050000000000001
2017-08-01T12:00:00Z 30.350000000000023
2017-08-06T12:00:00Z 31.550000000000001
```

#### *Les températures les plus froides à Nice*

```
SELECT BOTTOM(t,3)-273 FROM synop WHERE numer_sta = '07690'
name: synop
time                bottom
----              -----
1999-01-31T03:00:00Z -1.1499999999999773
1999-01-31T06:00:00Z -1.75
2005-01-29T06:00:00Z -1.5500000000000114
```

#### *La hauteur minimale des nuages à Nice*

```
> SELECT MIN(hbas) FROM synop WHERE numer_sta = '07690'
name: synop
time                min
----              ---
2000-04-22T18:00:00Z 2
```

#### *La dernière mesure de hauteur des nuages à Nice*

```
> SELECT LAST(hbas) FROM synop WHERE numer_sta = '07690'
name: synop
time                last
----              ----
2017-12-31T21:00:00Z 450
```

### **4.8.5. Transformation**

### Différence entre deux valeurs successives

```
> SELECT hbas FROM synop WHERE numer_sta = '07690' AND time >= '2017-04-06T00:00:00Z'
AND time <= '2017-04-06' + 2d
```

name: synop

| time                 | hbas |
|----------------------|------|
| ----                 | ---- |
| 2017-04-06T12:00:00Z | 800  |
| 2017-04-06T15:00:00Z | 800  |
| 2017-04-06T18:00:00Z | 1250 |
| 2017-04-07T06:00:00Z | 450  |
| 2017-04-07T09:00:00Z | 450  |
| 2017-04-07T12:00:00Z | 250  |
| 2017-04-07T15:00:00Z | 450  |

```
> SELECT DIFFERENCE(hbas) FROM synop WHERE numer_sta = '07690' AND time >= '2017-04-
06T00:00:00Z' AND time <= '2017-04-06' + 2d
```

name: synop

| time                 | difference |
|----------------------|------------|
| ----                 | -----      |
| 2017-04-06T15:00:00Z | 0          |
| 2017-04-06T18:00:00Z | 450        |
| 2017-04-07T06:00:00Z | -800       |
| 2017-04-07T09:00:00Z | 0          |
| 2017-04-07T12:00:00Z | -200       |
| 2017-04-07T15:00:00Z | 200        |

### Ecart type d'humidité à Nice au mois de février

```
> SELECT STDDEV(u) FROM synop WHERE time > '2017-02-01' AND time < '2017-02-28' AND
numer_sta = '07690'
```

name: synop

| time                           | stddev             |
|--------------------------------|--------------------|
| ----                           | -----              |
| 2017-02-01T00:00:00.000000001Z | 10.307574672600488 |

## 5. Un aperçu de l'administration d'InfluxDB

Quelques éléments pour pouvoir anticiper les modalités d'administration d'un influxDB en conditions réelles.

Ce qui suit est extrait de la documentation et inspiré d'un article paru sur [Gnu Linux Magazine France](#). Dans cet article, les exemples sont ceux de la documentation en ligne InfluxDB. La version traitée était la 0.13... Il va de soi que les exemples suivants sont de notre cru.

### 5.1. Sauvegarde et restauration

Il est nécessaire de sauvegarder :

- les métadonnées contenues dans le metastore

*Commande de sauvegarde du metastore*

```
sudo docker exec -it fdu-influxdb mkdir /var/lib/influxdb/backup
sudo docker exec -it fdu-influxdb influxd backup /var/lib/influxdb/backup
```

- toutes les bases

*Commandes de sauvegarde des databases*

```
sudo docker exec -it fdu-influxdb backup -database test_mesures
/var/lib/influxdb/backup
sudo docker exec -it fdu-influxdb backup -database telegraf /var/lib/influxdb/backup
etc...
```

Pour la restauration :

*Commandes de restauration*

```
sudo docker exec -it fdu-influxdb influxd restore -metadir /var/lib/influxdb/meta
/var/lib/influxdb/backup
influxd restore -database /var/lib/influxdb/data /var/lib/influxdb/backup
sudo docker exec -it fdu-influxdb chown -R influxdb /var/lib/influxdb
```

puis relance du container.

### 5.2. Gestion des logs

Sur un binaire classique, les logs sont stockées dans `/var/log/influxdb/influxd.log`.

Dans un container, on les retrouve sur la sortie standard, récupérable si le container est détaché via la commande `docker logs <nom_du_container>`.

Il y a 3 catégories de logs par défaut, `[meta]`, `[data]` et `[http]` configurables via fichier de

configuration transmissible au moment du `docker run` pour le container.

## 5.3. Authentification et autorisations

Toutes les expérimentations contenues dans ce rapport sont réalisées sans authentification.

La synthèse de la documentation est la suivante: la politique d'authentification et d'habilitations ressemble à celle des SGBDR.

### *Activation*

Il faut créer un utilisateur "DB" d'administration, modifier le paramètre **auth-enabled** de la section [http] du fichier de configuration.

Ci-dessous des commandes classiques ressemblantes aux SGBDR ordinaires :

### *Gestion des utilisateurs*

- **CREATE USER**
- **DROP USER**
- **SHOW USERS**

### *Les habilitations*

- **READ**
- **WRITE**
- **ALL**

### *Gestion des droits*

- **GRANT**
- **REVOKE**

## 5.4. Politique de rétention

InfluxDB propose une fonctionnalité de suppression de la donnée au bout d'un certain temps.

Quand on ne précise pas de politique de rétention à la création du measurement, on récupère la politique par défaut :

```
> SHOW RETENTION POLICIES ON test_mesures
name      duration shardGroupDuration replicaN default
-----
autogen 0s      168h0m0s      1      true
```

Si duration vaut 0 alors la rétention est infinie.



```
> CREATE RETENTION POLICY trente_jours ON test_mesures DURATION 30d REPLICATION 1
```

Pour utiliser cette politique, il faut préciser le paramètre **rp** lors de l'insertion des points :

Utilisation de la retention policy "trente\_jours"

```
> INSERT INTO trente_jours mesure_station,id_station=tttt,altitude_station=500i
temperature=15,pression=1.0
```

On note que l'on n'a pas précisé de timestamp pour se situer par défaut à la date actuelle.

Par contre, pour obtenir les points insérés, il faudra préciser la politique de rétention :

*SELECT sans paramètre RP*

```
> select * from mesure_station
name: mesure_station
time                altitude_station id_station pression temperature
----                -
1970-01-17T10:43:20Z 200i          xxxx      1.2      20
1970-01-17T10:45:00Z 500i          zzzz       1       15
2018-02-03T18:44:00.139560729Z 2000i        yyyy      0.9      30
```

*SELECT avec paramètre RP*

```
> select * from trente_jours.mesure_station
name: mesure_station
time                altitude_station id_station pression temperature
----                -
2018-05-08T18:31:40.40178337Z 500i          tttt       1       15
2018-05-08T18:56:48.314248631Z 500i          tttt       1       15
```

## 5.5. Requêtes en continu ou Continuous request

Cette fonctionnalité permet d'ordonnancer périodiquement une requête d'agrégation pour éventuellement stocker le résultat dans une autre base.

On retrouve le principe du streaming présent dans d'autres "frameworks" ou SGBD NOSQL.

## 5.6. Clustering

Il est quasiment systématique de faire rimer production avec cluster pour un SGBD.

C'est ce que l'on se propose de découvrir dans cette partie.

Comme dit précédemment, la partie clustering d'InfluxDB n'est disponible que dans sa version commerciale donc payante, **InfluxEnterprise**.

Fort heureusement pour le projet, InfluxData propose la possibilité de tester gratuitement pendant une période limitée (14 jours), son produit complet. InfluxData, nous impose de le faire au travers de son cloud **InfluxCloud**, méthode que l'on décrira ci après.

Mais avant cela, nous allons synthétiser les informations disponibles dans la documentation officielle publique.

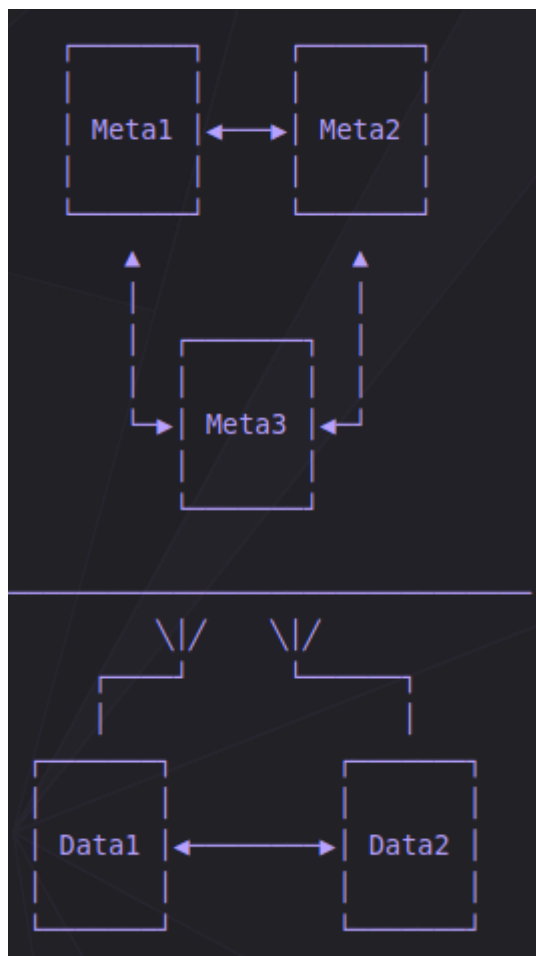
### 5.6.1. L'architecture d'un cluster InfluxDB

Une installation standard d'un cluster InfluxEnterprise consiste en 3 composants :

- Datanodes
- Metanodes
- Un serveur web, permettant la répartition de la charge

Un cluster influxDB ne requiert vraiment que les deux premiers pour fonctionner. C'est d'ailleurs pour cela que le serveur web est laissé au choix de l'utilisateur. Par contre, à sa charge de le configurer pour gérer une partie fournie dans d'autres SGBD NOSQL, la répartition des requêtes sur les noeuds.

*Un schéma de l'architecture du cluster InfluxDB*



*Les ports du cluster*

- entre datanodes (Protobuf) : **8088**
- entre metanodes (Raft) : **8089**

- datanodes et metanodes : **8091**

### *Les metanodes InfluxdDB*

Leur rôle est la gestion du metastore donc de l'ensemble des informations partagées de gestion du cluster :

- les informations relatives aux noeuds du cluster
- les "databases"
- les "retention policies"
- L'index des shard group
- La sécurité ("users", habilitations...)
- Les "continuous queries"
- Les "subscriptions" (Abonnements à destination de consommateurs tels Kapacitor, sujet non approfondi dans ce projet)

Il doit toujours y avoir au minimum 3 metanodes dans un cluster, et dans tous les cas, toujours un nombre impair.

Il n'y a pas forcément de correspondance metanode / serveur mais il est déconseillé par la documentation de faire cohabiter sur un même OS deux metanodes.

### *Le protocole Raft*

Pour gérer l'état du cluster, les metanodes utilisent le *protocole de consensus "Raft"*.

Comme on peut le voir dans cette [référence de la documentation officielle](#), l'objectif de ce protocole est de privilégier La **consistance et le partitionnement** sur la tolérance aux pannes.

Son fonctionnement en ce qui concerne le rôle des metanodes est de les restreindre à 3 :

- suiveur (*follower*)
- candidat (*candidate*)
- dirigeant (*leader*)  
en fonction du vote des autres noeuds.

Le candidat devenu *leader* seul reçoit les requêtes clients, et réplique les "logs entries" dans les machines à état des noeuds du cluster. C'est le second principe clé de Raft. Il est semblable à Paxos en terme de performances.

Le protocole Raft est décrit plus en détails ici :

<https://ramcloud.stanford.edu/wiki/download/attachments/11370504/raft.pdf>

Un cluster de 3 noeuds peut tolérer une panne. Un cluster de 5 noeuds peut en tolérer deux. Ce sont les deux valeurs avec le meilleur compromis performance/disponibilité recommandées .

### *Installation du meta node*

L'installation est décrite en détails dans la documentation officielle [ci-après](#).

InfluxCloud propose une installation du cluster déjà faite.

Datanodes gèrent :

- les measurements
- les tags, clés et valeurs
- les champs, clés et valeurs
- les groupes de shard
- les réponses aux requêtes transmises
- Ils requêtent également des informations (index) auprès du metagroup

Le nombre minimal : 2 datanodes, le nombre recommandé étant un multiple quelconque du facteur de réplication.

Leur protocole de fonctionnement est le *protocole buffers* ou *\_protobuf* de Google décrit plus en détails ici :

<https://developers.google.com/protocol-buffers/>

|            |   |
|------------|---|
| <b>TIP</b> | les données se trouvent par défaut dans<br><code>/var/lib/influxdb/data/&lt;database&gt;/&lt;retention_policy&gt;/&lt;shard_id&gt;</code> |
|------------|---|

### 5.6.2. Création d'un cluster InfluxDB dans le cloud InfluxData / AWS

Afin d'obtenir un environnement de tests InfluxEntreprise, à part s'offrir la licence, il n'y a pas d'autre possibilité que de souscrire, moyennant transmission de ses coordonnées bancaires (...), à l'offre cloud d'InfluxData. L'infrastructure est fournie par le cloud d'Amazon, AWS.

Les [caractéristiques du cluster cloud](#) sont décrites en annexe.

Au point de cette étude, et sans moyen de vérifier, on espère pouvoir manipuler les serveurs constituant le cluster pour pouvoir effectuer les tests de failover automatique, répartition des shards etc...

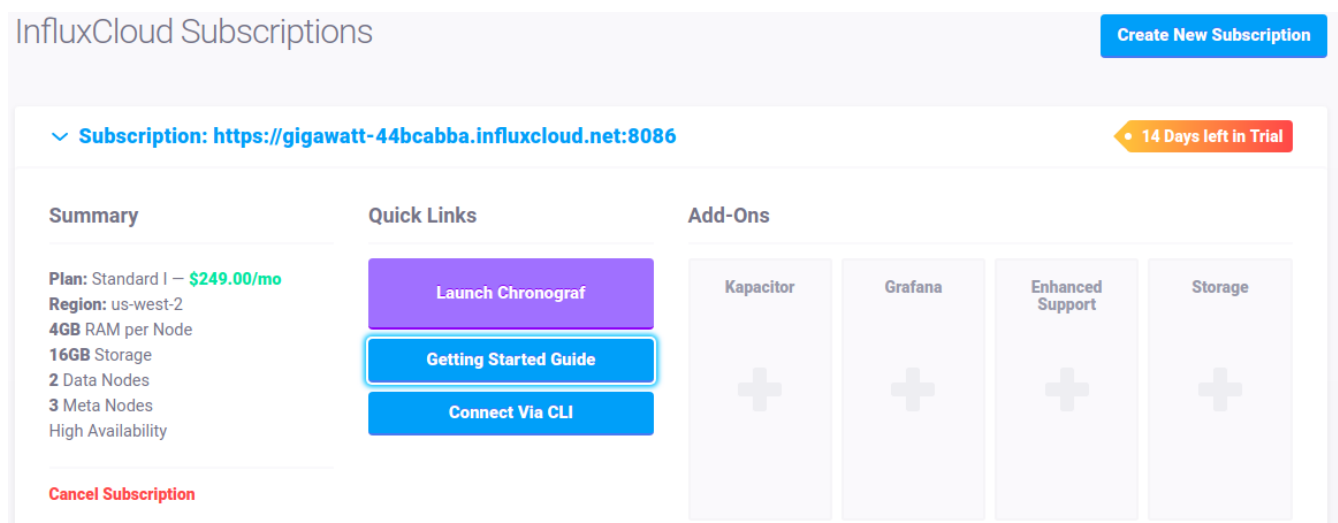


Figure 1. Éléments de configuration du cluster

A la première connexion via le CLI, on se rend compte que ce n'est pas la dernière version (1.5.2)

qui est disponible, mais l'avant dernière (1.5.1). Il est dommage que cela ne figure nulle part, car il est conseillé d'avoir les mêmes niveaux de version entre client et service...

#### Deuxième connexion de test via CLI influx

```
15:08:07-user@M40474:~/Bureau/CNAM/git/CNAM-projets(master)$ sudo docker run --rm
--name influx_cloud -it influxdb:1.5.1 influx -precision rfc3339 -username
f.dunan@probt.com -password xxxxxxxxx -host gigawatt-44bcabba.influxcloud.net -ssl
-unsafeSsl -port 8086
Unable to find image 'influxdb:1.5.1' locally
1.5.1: Pulling from library/influxdb
c73ab1c6897b: Pull complete
1ab373b3deae: Pull complete
b542772b4177: Pull complete
2546b96148b0: Pull complete
56b54f39c74f: Pull complete
5fbdf2fbf43e: Pull complete
ef4784e7446b: Pull complete
c9ff778fe79c: Pull complete
Digest: sha256:3facbd59e92e90a9ef8dd646fae64576b6500b7b7ab0fb7cf98d50216a2cdcc2
Status: Downloaded newer image for influxdb:1.5.1
Connected to https://gigawatt-44bcabba.influxcloud.net:8086 version 1.5.1-c1.5.1
InfluxDB shell version: 1.5.1
> SHOW DATABASES
name: databases
name
---
_internal
state_fair_db
meteo
```

#### Quelques informations supplémentaires

```
> SHOW DIAGNOSTICS
...
name: config
bind-address gossip-frequency hostname
reporting-disabled
-----
:8088      3s      prod-44bcabba-us-west-2-data-4.influxdata.local true
...
name: config-httpd
access-log-path bind-address enabled https-enabled max-connection-limit max-row-limit
-----
:8086      true    false    0      0
```

```
...
name: config
bind-address gossip-frequency hostname
reporting-disabled
-----
-----
:8088          3s          prod-44bcabba-us-west-2-data-3.influxdata.local true
```

### 5.6.3. InfluxCloud est insuffisant pour se faire une idée du cluster !

Malheureusement, seul le port d'interaction avec InfluxDB est ouvert. Impossible de contacter metanodes et datanodes directement.

La commande suivante, censée donner l'état des shard, échoue :

*Tentatives d'utilisation d'influx-ctl, le CLI du cluster*

```
00:17:26-user@M40474:~/Bureau/CNAM/git/CNAM-projets(master)$ sudo docker run --rm
--name influx_cloud_ctl -it influxdb:meta influxd-ctl -auth-type basic -user
f.dunan@probt.com -pwd xxxxxxxx -bind-tls -k -bind gigawatt-
44bcabba.influxcloud.net:8091 copy-shard-status

00:17:56-user@M40474:~/Bureau/CNAM/git/CNAM-projets(master)$ sudo docker run --rm
--name influx_cloud_ctl -it influxdb:meta influxd-ctl -auth-type basic -user
f.dunan@probt.com -pwd xxxxxxxx -bind-tls -k -bind gigawatt-
44bcabba.influxcloud.net:8091 show-shards

00:17:56-user@M40474:~/Bureau/CNAM/git/CNAM-projets(master)$ sudo docker run --rm
--name influx_cloud_ctl -it influxdb:meta influxd-ctl -auth-type basic -user
f.dunan@probt.com -pwd xxxxxxxx -bind-tls -k -bind gigawatt-
44bcabba.influxcloud.net:8091 show
```

La documentation des [commandes cluster](#) n'aura hélas pas beaucoup servi.

On ne pourra donc pas "jouer" avec l'extinction des datanodes et metanodes, constater la répartition... c'est une déception de taille car lors du choix d'InfluxDB, si le fait de ne pouvoir bénéficier de toutes les fonctionnalités pouvait sembler redhibitoire a priori, la présence d'un cloud de test de la version complète avait rendu l'étude d'InfluxDB intéressante...

Comment évaluer le mode de failover automatique d'InfluxDB autrement que sur le papier ?

Et dans une moindre mesure, on a pris le risque d'un achat internet avec ses propres moyens de paiement....

#### *Partitionnement*

Sur cet aspect crucial, on devra se contenter d'un aspect documentaire...et il semble que l'on aille de charybde en scylla : D'après [la documentation sur le repartitionnement](#) il semblerait que la répartition des shard dans un cluster influxdb se fasse manuellement ...

## 5.6.4. Exploitation du cluster avec l'ensemble des données de l'approfondissement

Pour autant, on va pouvoir bénéficier de la puissance de calcul de la mémoire pour charger l'intégralité des 23 années de mesures météo avec toutes les variables !

*Essai avec le même nombre de variables*

```
12:38:17-user@M40474:~/Bureau/CNAM/git/CNAM-projets/NFE204(master)$ for i in
donnees/extractions/*;do python3 ../../csv-to-influxdb/csv-to-influxdb.py -d';' -s
'gigawatt-44bcabba.influxcloud.net:8086' -m 'synop' -tc 'date' -tf '%Y%m%d%H%M%S'
--fieldcolumns pmer,tend,dd,ff,td,u,vv,hbas,tnN,txN,rafer,pres,t --tagcolumns
numer_sta --dbname meteo -u f.dunan@probt.com -p xxxxxxxx --input $i;done
```

*Impact sur les shards*

```
name: meteo
id   database retention_policy shard_group start_time          end_time
expiry_time      owners
--  -
-----
5    meteo    autogen          3          1996-01-01T00:00:00Z 1996-01-08T00:00:00Z
1996-01-08T00:00:00Z 4,5
...
1093 meteo    autogen          1091        2017-12-18T00:00:00Z 2017-12-25T00:00:00Z
2017-12-25T00:00:00Z 4,5
1094 meteo    autogen          1092        2017-12-25T00:00:00Z 2018-01-01T00:00:00Z
2018-01-01T00:00:00Z 5,4
```

On note l'ordre des datanodes dans la colonne owners

*Commande insertion complète*

```
14:46:49-user@M40474:~/Bureau/CNAM/git/CNAM-projets/NFE204(master)$ for i in
donnees/extractions/*;do python3 ../../csv-to-influxdb/csv-to-influxdb.py -d';' -s
'gigawatt-44bcabba.influxcloud.net:8086' -m 'synop' -tc 'date' -tf '%Y%m%d%H%M%S'
--fieldcolumns
pmer,tend,dd,ff,td,u,vv,hbas,tnN,txN,rafer,pres,t,cod_tend,td,vv,ww,w1,w2,n,nbas,cl,c
m,ch,niv_bar,geop,tend24,tn12,tn24,tx12,tx24,tminsol,sw,tw,raf10,rafer,per,etat_sol,h
t_neige,ssfrai,perssfrai,rr1,rr3,rr6,rr12,rr24,phenspe1,phenspe2,phenspe3,phenspe4,nnu
age1,ctype1,hnuage1,nnuage2,ctype2,hnuage2,nnuage3,ctype3,hnuage3,nnuage4,ctype4,hnuag
e4 --tagcolumns numer_sta --dbname meteo -u f.dunan@probt.com -p xxxxxxxx --input
$i;done
```

*Nombre....et bug !*

```
> SELECT * FROM synop LIMIT 5
ERR: %!s(<nil>)
```

La description du [bug de requête sur un count trop important que l'on expérimente là](#).

pourtant :

```
name: meteo
id   database retention_policy shard_group start_time      end_time
expiry_time      owners
--  -----
-----
1095 meteo     autogen          1093      1996-01-01T00:00:00Z 1996-01-08T00:00:00Z
1996-01-08T00:00:00Z 5,4

...

2226 meteo     autogen          2224      2017-12-18T00:00:00Z 2017-12-25T00:00:00Z
2017-12-25T00:00:00Z 4,5
2227 meteo     autogen          2225      2017-12-25T00:00:00Z 2018-01-01T00:00:00Z
2018-01-01T00:00:00Z 5,4
```

et



```

> SELECT * FROM synop LIMIT 5
name: synop
time                ch cl cm cod_tend ctype1 ctype2 ctype3 ctype4 dd  etat_sol ff
geop hbas hnuage1 hnuage2 hnuage3 hnuage4 ht_neige n  nbas niv_bar nnuage1 nnuage2
nnuage3 nnuage4 numer_sta per perssfrai phenspe1 phenspe2 phenspe3 phenspe4 pmer
pres raf10 rafper rr1 rr12 rr24 rr3 rr6 ssfrai sw t      td      tend tend24 tminsol
tn12  tn24 tw tx12  tx24 u   vv   w1 w2 ww
-----
-----
-----
-----
-----
1996-01-01T00:00:00Z      1              170      2
07005                    100030 99090
0          276.04 275.95 100              99
1996-01-01T00:00:00Z 11 30 23 4              100      2
2250                    25  1
89642                    98820 98290
271.15 261.65 10          265.65          271.65      44 40000
1996-01-01T00:00:00Z 60 62 61 1              0      0
101                    07015
100020 99380              0          275.95 275.35 100
96 300  4  4  45
1996-01-01T00:00:00Z 60 36 61 0          7      6          120      4.1
250 180      1500          90  7          3      6
07027                    99940 99130
0  0          279.04 279.04 0              100
1200  5  4  28
1996-01-01T00:00:00Z 60 36 61 8          7          110      1
70  60          100 8          8
07130                    99900 99380
0          281.25 280.65 -10              96 800  8
6  46

```

On a quand même réussi à insérer l'ensemble des lignes ~ **23 ans x 15000 lignes x 59 colonnes** !

Ci après un exemple de ce que l'on peut faire avec avec le chronograph mis à disposition de l'utilisateur du cloud : Ici l'évolution des températures moyennes mensuelles sur plusieurs années.

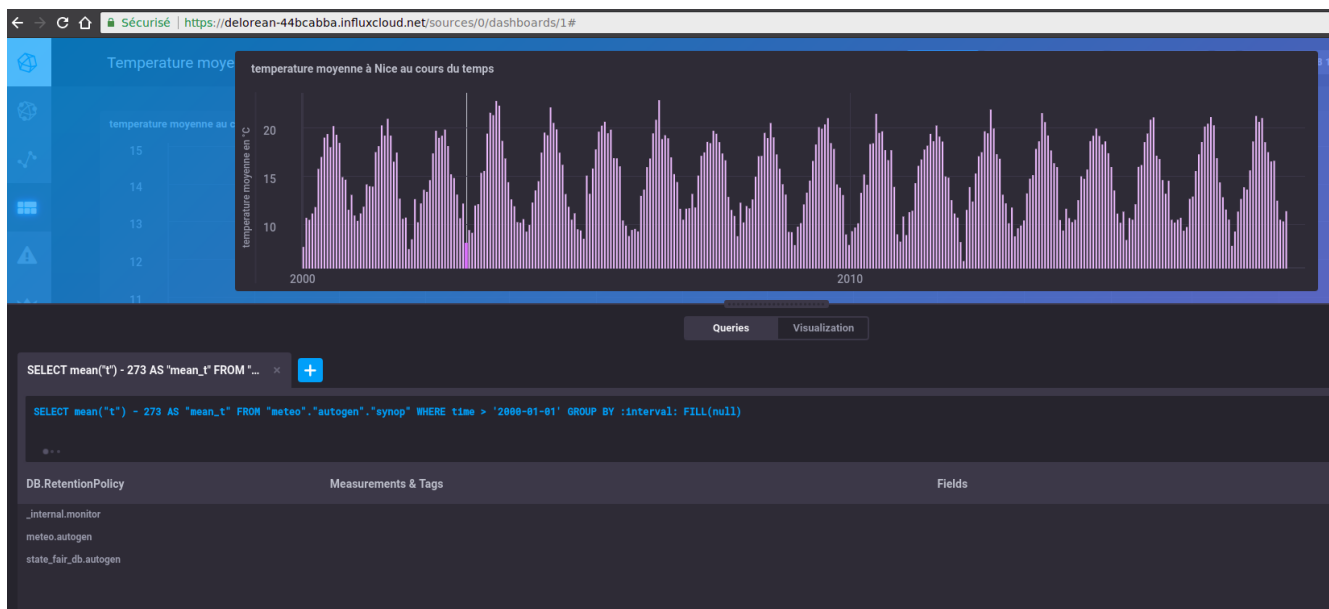


Figure 2. élaboration de la requête dans chronograf




Figure 3. zoom sur la visualisation

## 6. Conclusion et approfondissements envisageables

A l'usage simple et rapide, ayant un écosystème, un langage de requêtes et une [documentation](#) ultra-riches, plébiscité par des utilisateurs, dynamique en terme d'activité, on comprend mieux pourquoi InfluxDB est un leader en terme de TSDB.

Néanmoins, l'appréhension du modèle de données est exigeante et "perd" parfois ses utilisateurs. Certains [choix de conception](#) sont aussi discutables. A l'usage, il faut être attentif aux problématiques d'utilisation de la mémoire, surtout si on est limité en cette ressource.

Enfin le fait que le clustering soit payant et qu'il n'y en n'ait qu'un vague aspect est à la fois une des faiblesses de cette étude mais aussi un gros point d'interrogation sur l'efficacité d'InfluxDB en production notamment pour ses administrateurs : Si le re-partitionnement après ajout d'un noeud est manuel, on sera loin des canons d'élasticité automatique du moment dans le domaine du SGBD NoSQL.

On aura durant cette étude, appris les nombreuses notions originales d'InfluxDB....notamment en solutionnant les problèmes rencontrés : choisir un tag n'ayant pas une grande cardinalité, faire des projections sur des informations bien choisies...On aura également effleuré le domaines de la mesure physique, générateurs d'un gros volume de données.

Malgré cela, les qualités d'InfluxDB offrent des perspectives de prolongation d'étude. Ci-après quelques points :

- Utiliser les données contenues dans InfluxDB pour être le support d'un modèle de classification ou de prédiction.
- Construire une ou plusieurs variables géographiques afin de proposer des tags supplémentaires et ainsi, obtenir des informations par latitudes ou par régions. Une approche relationnelle classique aurait été de construire une table dédiée, mais l'absence de jointure et le fait que la table n'aurait rien d'une time, justifierait la création d'une colonne de type 'tag'.
- Approfondir les "continuous requests".
- Lors de l'utilisation du cluster, modifier le niveau de consistance des écritures au CLI (consistency <level> sets write consistency level: any, one, quorum, or all) et différencier les timings d'insertion
- Explorer **IFQL**
- Acquérir une licence commerciale pour finir l'évaluation d'un cluster.

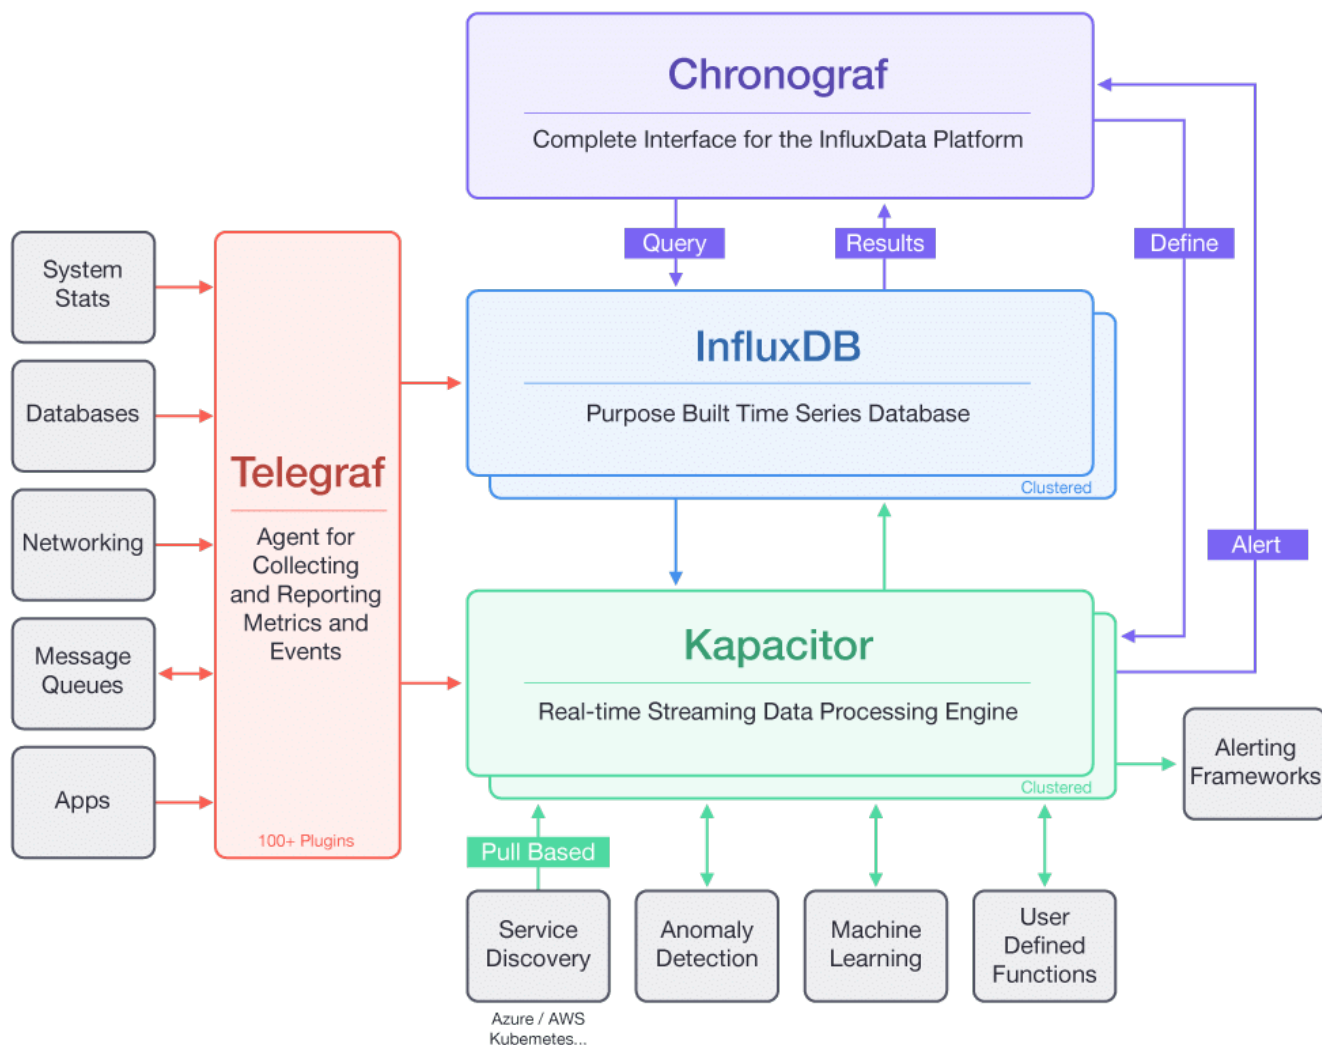
Et sans doute bien d'autres choses encore !

# Appendix A: Annexes

## A.1. En savoir plus sur la stack TICK

### A.1.1. Architecture

Ci-dessous, le schéma des interactions entre InfluxDB et ses compagnons.



### A.1.2. Telegraf

C'est l'agent pour collecter les métriques et les insérer dans InfluxDB.

*Une configuration de Telegraf*

```
[agent]
interval = "1s"
round_interval = true
metric_batch_size = 1000
metric_buffer_limit = 10000
collection_jitter = "0s"
flush_interval = "1s"
flush_jitter = "0s"
```

```

precision = ""
debug = true
quiet = false
#logfile = "/tmp/telegraf.log"

hostname = ""
omit_hostname = false

[[inputs.logparser]]
  ## file(s) to tail:
  files = ["/home/user/Bureau/CNAM/git/CNAM-projets/donnees/meteoFrance/meteo-2017_11-sample.csv"]
  from_beginning = true
  ## For parsing logstash-style "grok" patterns:
  [inputs.logparser.grok]
    #patterns = ['%{WORD:numer_sta:tag};%{INT:date:ts-
"20060102150405"};%{INT:pmer_Pa};%{INT:tend_Pa};%{INT:cod_tend:drop};%{INT:dd_deg:drop
};%{BASE10NUM:ff_m-
s};%{BASE10NUM:temp_K};%{BASE10NUM:td_K:drop};%{INT:u_};%{BASE10NUM:vv_m:drop};%{INT:
ww:drop};%{INT:w1:drop};%{INT:w2:drop};%{BASE10NUM:n_};%{INT:nbas:drop};%{INT:hb
as:drop};%{INT:cl:drop};%{INT:cm:drop};%{INT:ch:drop};%{INT:pres_Pa};%{INT:niv_bar_Pa:
drop};%{INT:geop:drop};%{INT:tend24_Pa};%{BASE10NUM:tn_K};%{BASE10NUM:txN_K};%{BASE10N
UM:tminsol_K};%{INT:sw_code:drop};%{BASE10NUM:tw_K:drop};%{BASE10NUM:raf10_m-
s};%{BASE10NUM:rafper_m-
s};%{BASE10NUM:per_min};%{INT:etat_sol_code:drop};%{BASE10NUM:ht_neige_m};%{BASE10NUM:
ssfrai_m};%{BASE10NUM:perssfrai_01m};%{BASE10NUM:rrN_mm};%{BASE10NUM:phenspeN:drop};%{
INT:nnuageN_octa:drop};%{INT:ctypeN_code};%{INT:hnuageN_m};%{WORD:drop:drop}']
    patterns = ['%{WORD:numer_sta};%{INT:date:ts-
"20060102150405"};%{INT:pmer_Pa:int};%{INT:tend_Pa:int};%{INT:cod_tend:drop};%{INT:dd_
deg:drop};%{NUMBER:ff_m_s:float};%{NUMBER:temp_K:float};%{NUMBER:td_K:drop};%{INT:u_p1
00:int};%{NUMBER:vv_m:drop};%{INT:ww:drop};%{INT:w1:drop};%{INT:w2:drop};%{NUMBER:n_p1
00:drop};%{INT:nbas:drop};%{INT:hbases:drop};%{INT:cl:drop};%{INT:cm:drop};%{INT:ch:drop
};%{INT:pres_Pa:int};%{INT:niv_bar_Pa:drop};%{INT:geop_code:drop};%{INT:tend24_Pa:int}
;%{NUMBER:tn_K:float};%{NUMBER:txN_K:float};%{NUMBER:tminsol_K:float};%{INT:sw_code:d
rop};%{NUMBER:tw_K:drop};%{NUMBER:raf10_m_s:float};%{NUMBER:rafper_m_s};%{NUMBER:per_m
in:float};%{INT:etatsol:drop};']

[[outputs.file]]
  ## Files to write to, "stdout" is a specially handled file.
  files = ["stdout"]

#[[outputs.influxdb]]
  ## The full HTTP or UDP endpoint URL for your InfluxDB instance.
  #urls = ["http://localhost:8086"] # required
  ## The target database for metrics (telegraf will create it if not exists).
  #database = "mesures_stations_meteo" # required
  ## Write timeout (for the InfluxDB client), formatted as a string.
  #timeout = "5s"

```

### A.1.3. Chronograf

C'est l'outil de visualisation pour les données temporelles dans InfluxDB.

Il permet également de gérer InfluxDB à l'aide d'une interface web.

### A.1.4. Kapacitor

Ce client est dédié à la supervision et à la gestion des alertes.

## A.2. Tableaux de synthèse des fonctions IQL

Par convention, l'argument 'champs' signifiera un ou plusieurs "field key".

### A.2.1. Les fonctions d'agrégation

Les fonctions d'agrégation classiques suivantes ont cours avec InfluxDB :

| Nom fonction                | Effet   |
|-----------------------------|---|
| <i>COUNT(champs)</i>        | Rend l'effectif   |
| <i>DISTINCT(champs)</i>     | Rend les modalités d'un champ   |
| <i>INTEGRAL(champ,time)</i> | Calcule l'aire sous la courbe représentée par les points sélectionnés |
| <i>MEAN(champs)</i>         | Calcule la moyenne arithmétique                                       |
| <i>MEDIAN(champs)</i>       | Rend la médiane des champs  |
| <i>MODE(champs)</i>         | Rend la valeur la plus fréquente                                      |
| <i>SPREAD(champs)</i>       | Rend la différence entre min et max                                   |
| <i>STDDEV(champs)</i>       | Rend l'écart type   |
| <i>SUM(champs)</i>          | Rend la somme des champs  |

### A.2.2. Les fonctions de sélection

| Nom fonction                 | Effet  |
|------------------------------|--|
| <i>BOTTOM(champs)</i>        | Rend les plus petites valeurs                                  |
| <i>FIRST(champs)</i>         | Rend la valeur avec l'estampille la plus ancienne              |
| <i>LAST(champs)</i>          | Rend la valeur avec l'estampille la plus récente               |
| <i>MAX(champs)</i>           | Rend la valeur du champ maximum                                |
| <i>MIN(champs)</i>           | Rend la valeur du champ minimum                                |
| <i>PERCENTILE(champs, N)</i> | Rend la valeur du champ supérieure aux N% des valeurs du champ |
| <i>SAMPLE(champs, N)</i>     | Rend un échantillon aléatoire de N valeurs                     |
| <i>TOP(champs,N)</i>         | Rend les N plus grandes valeurs                                |

### A.2.3. Les fonctions de transformation

Elles permettent d'obtenir un résultat entre deux valeurs d'une même mesure.

| Nom fonction                      | Effet  |
|-----------------------------------|--|
| CEILING()                         | Non implémentée cf documentation.  |
| CUMULATIVE_SUM(champs)            | Calcule la somme des champs sur une période.   |
| DERIVATIVE(champs,N)              | Rend le taux de variation entre 2 mesures qui se suivent.  |
| DIFFERENCE(champs)                |  |
| ELAPSED(champs)                   | Rend la différence entre 2 timestamps dont les points se suivent   |
| FLOOR()                           | Non implémentée cf documentation.  |
| HISTOGRAM()                       | Non implémentée cf documentation.<br>(ne fonctionne pas cf <a href="https://github.com/influxdata/influxdb/issues/5930">https://github.com/influxdata/influxdb/issues/5930</a> ) |
| MOVING_AVERAGE(champs, N)         | Rend la moyenne mobile sur une fenêtre de N points   |
| NON_NEGATIVE_DERIVATIVE(champs,N) | Idem DIFFERENCE mais ne rend que la valeur absolue   |
| NON_NEGATIVE_DIFFERENCE()         | Idem DIFFERENCE mais ne rend que la valeur absolue   |

### A.2.4. Prédicteur

La fonction **HOLT\_WINTERS()** est disponible pour :

- Prédire quand les valeurs vont passer un seuil donné
- Comparer les données prédites et réelles pour détecter des anomalies.

cf [https://docs.influxdata.com/influxdb/v1.5/query\\_language/functions/#examples-18](https://docs.influxdata.com/influxdb/v1.5/query_language/functions/#examples-18) pour un exemple, elle n'est pas testée dans cette étude.

## A.3. Eléments techniques (Installation, paramétrage...) d'InfluxDB

### A.3.1. Matériel de tests

Dans cette étude, on utilisera comme plateforme un laptop Lenovo T430s avec ubuntu 17.10 installé.

### A.3.2. InfluxDB et docker

- Installation et démarrage

On dispose de deux méthodes :

#### *Installation du paquet Ubuntu*

```
sudo apt-get influxdb
```

Cependant, la version du [package ubuntu d'influxDb](#) est obsolète (1.1.1)

On préférera la dernière version officielle de [l'image docker](#) (1.5.2)

```
sudo mkdir /var/opt/influxdb

docker network create influxdb

sudo docker run -d -p 8086:8086 \
    -v /home/user/Bureau/CNAM/git/CNAM-
projets/NFE204/etc/influxdb.conf:/etc/influxdb/influxdb.conf:ro \
    -v /var/opt/influxdb:/var/lib/influxdb \
    -e INFLUXDB_REPORTING_DISABLED=true \
    --name fdu-influxdb \
    influxdb -config /etc/influxdb/influxdb.conf
```

#### *Pour ajouter un réseau link (deprecated)*

```
--net=influxdb \
```

On vérifie que InfluxDB a bien fonctionné par un "ping" REST.

#### *Ping REST*

```
user@M40474:~/Bureau/CNAM/git/CNAM-projets/donnees/meteoFrance$ curl -sl -I `sudo
docker inspect -f '{{.NetworkSettings.IPAddress}}' fdu-influxdb`:8086/ping
HTTP/1.1 204 No Content
Content-Type: application/json
Request-Id: 7be68cbe-0853-11e8-860a-000000000000
X-Influxdb-Build: OSS
X-Influxdb-Version: 1.5.2
X-Request-Id: 7be68cbe-0853-11e8-860a-000000000000
Date: Fri, 02 Feb 2018 19:58:48 GMT
```

### **A.3.3. Logs de démarrage et extinction influxDB**



```
[I] 2018-01-30T20:44:25Z InfluxDB starting, version 1.5.2, branch 1.4, commit
6d2685d1738277a1c2672fc58df7994627769be6
[I] 2018-01-30T20:44:25Z Go version go1.9.2, GOMAXPROCS set to 4
```

```
88888888      .d888 888      88888888b. 8888888b.
 888          d88P" 888          888 "Y88b 888 "88b
 888          888  888          888  888 888  .88P
 888 888888b. 888888 888 888 888 888 888 888 88888888K.
 888 888 "88b 888 888 888 888 Y8bd8P' 888 888 888 "Y88b
 888 888 888 888 888 888 888 X88K 888 888 888 888
 888 888 888 888 888 Y88b 888 .d8""8b. 888 .d88P 888 d88P
88888888 888 888 888 888 "Y88888 888 888 88888888P" 88888888P"
```

```
[I] 2018-01-30T20:44:25Z Using configuration at: /etc/influxdb/influxdb.conf
[I] 2018-01-30T20:44:26Z Using data dir: /var/lib/influxdb/data service=store
[I] 2018-01-30T20:44:26Z opened service service=subscriber
[I] 2018-01-30T20:44:26Z Starting monitor system service=monitor
[I] 2018-01-30T20:44:26Z 'build' registered for diagnostics monitoring service=monitor
[I] 2018-01-30T20:44:26Z 'runtime' registered for diagnostics monitoring
service=monitor
[I] 2018-01-30T20:44:26Z 'network' registered for diagnostics monitoring
service=monitor
[I] 2018-01-30T20:44:26Z 'system' registered for diagnostics monitoring
service=monitor
[I] 2018-01-30T20:44:26Z Starting precreation service with check interval of 10m0s,
advance period of 30m0s service=shard-precreation
[I] 2018-01-30T20:44:26Z Starting snapshot service service=snapshot
[I] 2018-01-30T20:44:26Z Starting continuous query service service=continuous_querier
[I] 2018-01-30T20:44:26Z Starting HTTP service service=httpd
[I] 2018-01-30T20:44:26Z Authentication enabled:false service=httpd
[I] 2018-01-30T20:44:26Z Listening on HTTP:[::]:8086 service=httpd
[I] 2018-01-30T20:44:26Z Starting retention policy enforcement service with check
interval of 30m0s service=retention
[I] 2018-01-30T20:44:26Z Listening for signals
[I] 2018-01-30T20:44:26Z Storing statistics in database '_internal' retention policy
'monitor', at interval 10s service=monitor
```

```
[I] 2018-01-30T20:51:45Z Signal received, initializing clean shutdown...
[I] 2018-01-30T20:51:45Z Waiting for clean shutdown...
[I] 2018-01-30T20:51:45Z snapshot listener closed service=snapshot
[I] 2018-01-30T20:51:45Z shutting down monitor system service=monitor
[I] 2018-01-30T20:51:45Z terminating storage of statistics service=monitor
[I] 2018-01-30T20:51:45Z Precreation service terminating service=shard-precreation
[I] 2018-01-30T20:51:45Z continuous query service terminating
service=continuous_querier
[I] 2018-01-30T20:51:45Z Retention policy enforcement service closing.
service=retention
[I] 2018-01-30T20:51:45Z closed service service=subscriber
[I] 2018-01-30T20:51:45Z server shutdown completed
```

### A.3.4. Ports exposés

- 8086 port API HTTP
- 8083 port interface administration, supprimé à partir de la 1.3.0
- 2003 Graphite support, si activé

### A.3.5. Processus

*Nom du processus et du fichier binaire "serveur" InfluxDB*

```
influxd
```

*Fichier de configuration*

```
/etc/influxd/influxdb.conf
```

Principaux réglages:

- reporting des données à influxData
- répertoire de stockage des données
- répertoire de stockage des meta-données
- configuration du frontal embarqué (nginx)
- plugins de protocoles liés à d'autres outils (graphite, collectd, opentsdb, UDP...)

Bref, influxDB est riche...

### A.3.6. Bibliothèques python clientes

Les "bindings" python sont disponibles sous forme de paquet ubuntu :

```
apt-get install python-influxdb python3-influxdb
```

### A.3.7. CLI & CLI docker

Le client en ligne de commande est présent dans l'installation d'influxdb.

*binaire CLI influxdb*

```
/usr/bin/influx
```

Celui-ci est disponible également sous forme de paquet Ubuntu.

```
user@M40474:~$ apt-get install influxdb-client

user@M40474:~$ influx
Visit https://enterprise.influxdata.com to register for updates, InfluxDB server
management, and monitoring.
Connected to http://localhost:8086 version 1.5.2
InfluxDB shell version: 1.1.1
```

#### NOTE

Le CLI et InfluxDB devraient avoir des versions identiques. Sinon il y a un risque d'erreur d'analyse syntaxique des requêtes, cf [documentation](#) sur ce point.

On privilégiera donc l'image docker du CLI influx plus récente.

```
user@M40474:~$ sudo docker run --rm --name influx --link=fdu-influxdb -it influxdb
influx -precision rfc3339 -host `sudo docker inspect -f
'{{.NetworkSettings.IPAddress}}' fdu-influxdb`
Connected to http://172.17.0.2:8086 version 1.5.2
InfluxDB shell version: 1.5.2
```

*Portion de log sur le serveur dès la connection du client:*

```
[httpd] 172.17.0.4 - - [02/Feb/2018:09:21:39 +0000] "GET /ping HTTP/1.1" 204 0 "-"
"InfluxDBShell/1.5.2" 796914a1-07fa-11e8-8001-000000000000 196
```

#### TIP

Pour le paramétrage de la précision des dates, on utilisera rfc3339 au travers du paramètre -precision.

*Paramètres de -precision*

```
'rfc3339|h|m|s|ms|u|ns' Specifies the format/precision of the timestamp: rfc3339
(YYYY-MM-DDTHH:MM:SS.nnnnnnnnnZ), h (hours), m (minutes), s (seconds), ms
(millisecons), u (microseconds), ns (nanoseconds). Precision defaults to nanoseconds.
```

### A.3.8. Endpoints REST d'InfluxDB

Ci-dessous, une synthèse des méthodes ou "endpoints" proposées :

Table 3. "Endpoints" exposés

|                 |   |
|-----------------|---|
| /debug/requests | Utiliser /debug/requests/ pour tracer les requêtes HTTP aux "endpoints" /write et /query.                 |
| /ping           | Permet de vérifier le statut de l'instance InfluxDB. Donne également la version.                          |
| /query          | /query permet d'émettre des requêtes mais aussi de gérer les DB, utilisateurs et politiques de rétention. |
| /write          | /write permet d'insérer et dans une moindre mesure de mettre à jour dans une DB pré-existante.            |

Inutile de paraphraser la [documentation de l'API](#) d'InfluxDB qui est déjà très complète.

### A.3.9. Lancer Telegraf

Le besoin étant de faire fonctionner Telegraf comme injecteur à la demande, l'utilisation d'un container est moins pratique qu'un binaire. En effet, les modifications de configuration peuvent être nombreuses.

Le paquet ubuntu étant absent, on procède à une installation du paquet debian fourni par InfluxData.

*Téléchargement et installation de telegraf*

```
wget https://dl.influxdata.com/telegraf/releases/telegraf_1.5.2-1_amd64.deb
sudo dpkg -i telegraf_1.5.2-1_amd64.deb

service telegraf stop
```

Un fichier de configuration est fourni en [annexe](#).

On notera que dans la configuration du plugin InfluxDB de Telegraf, on peut régler les règles de commit dans un cluster InfluxDB :

```
## Write consistency (clusters only), can be: "any", "one", "quorum", "all"
```

D'ores et déjà, on voit que le client est maître, comme Cassandra, de la politique de consistance de l'écriture.

### A.3.10. Lancer Chronograf

Ici, on utilise un container pour obtenir un GUI web issu de [l'image docker officielle de Chronograf](#).

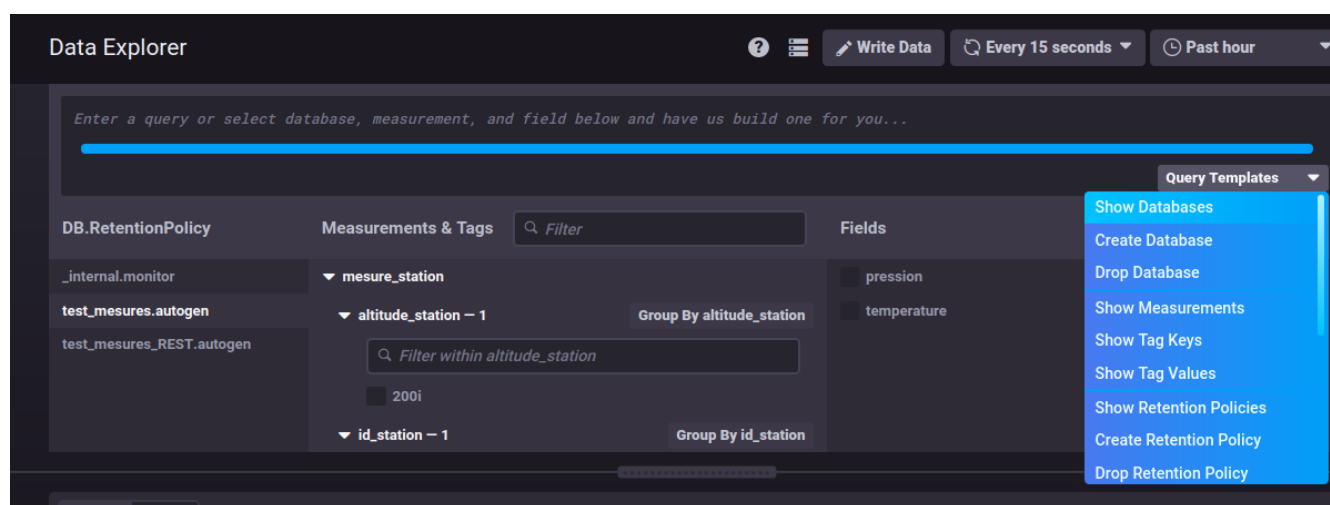
```
sudo docker run -p 8888:8888 chronograf \
  --influxdb-url=http://`sudo docker inspect -f '{{.NetworkSettings.IPAddress}}'
  fdu-influxdb`:8086
```

L'IHM web est atteignable sur le port 8888 du container via un navigateur.

Il faut d'abord procéder à une brève configuration :

Menu de gauche, item "configuration", "add-source" et renseigner l'URL de connexion. Un exemple : <http://172.17.0.2:8086>.

Ce qui nous permet, entre autres, d'obtenir à l'aide du menu "Data explorer", la liste des tables et des données.



### A.3.11. Lancer Kapacitor

Le monitoring et la gestion d'alerte pour un SGBD NoSQL dépassent le périmètre de l'étude. Pour aborder le sujet, consulter la [documentation officielle](#).

## A.4. Description des variables des données météo

# Paramètres inclus dans les fichiers de données SYNOP

| Descriptif  | Mnémonique | type | unité                       |
|---|------------|------|-----------------------------|
| Indicatif OMM station                                     | numer_sta  | car  |                             |
| Date (UTC)  | date       | car  | AAAAMMDDHHMISS              |
| Pression au niveau mer                                    | pmer       | int  | Pa                          |
| Variation de pression en 3 heures                         | tend       | int  | Pa                          |
| Type de tendance barométrique                             | cod_tend   | int  | <a href="#">code</a> (0200) |
| Direction du vent moyen 10 mn                             | dd         | int  | degré                       |
| Vitesse du vent moyen 10 mn                               | ff         | réel | m/s                         |
| Température   | t          | réel | K                           |
| Point de rosée  | td         | réel | K                           |
| Humidité  | u          | int  | %                           |
| Visibilité horizontale                                    | vv         | réel | m                           |
| Temps présent   | ww         | int  | <a href="#">code</a> (4677) |
| Temps passé 1   | w1         | int  | <a href="#">code</a> (4561) |
| Temps passé 2   | w2         | int  | <a href="#">code</a> (4561) |
| Nébulosité totale   | n          | réel | %                           |
| Nébulosité des nuages de l'étage inférieur                | nbas       | int  | octa                        |
| Hauteur de la base des nuages de l'étage inférieur        | hbas       | int  | mètre                       |
| Type des nuages de l'étage inférieur                      | cl         | int  | <a href="#">code</a> (0513) |
| Type des nuages de l'étage moyen                          | cm         | int  | <a href="#">code</a> (0515) |
| Type des nuages de l'étage supérieur                      | ch         | int  | <a href="#">code</a> (0509) |
| Pression station  | pres       | int  | Pa                          |
| Niveau barométrique                                       | niv_bar    | int  | Pa                          |
| Géopotentiel  | geop       | int  | m2/s2                       |
| Variation de pression en 24 heures                        | tend24     | int  | Pa                          |
| Température minimale sur N heures                         | tnN        | réel | K                           |
| Température maximale sur N heures                         | txN        | réel | K                           |
| Température minimale du sol sur 12 heures                 | tminsol    | réel | K                           |
| Méthode mesure tw   | sw         | int  | <a href="#">code</a> (3855) |
| Température du thermomètre mouillé                        | tw         | réel | K                           |
| Rafales sur les 10 dernières minutes                      | raf10      | réel | m/s                         |
| Rafales sur une période                                   | rafper     | réel | m/s                         |
| Période de mesure de la rafale                            | per        | réel | min                         |
| Etat du sol   | etat_sol   | int  | <a href="#">code</a> (0901) |
| Hauteur totale de la couche de neige, glace, autre au sol | ht_neige   | réel | m                           |
| Hauteur de la neige fraîche                               | ssfrai     | réel | m                           |
| Période de mesure de la neige fraîche                     | perssfrai  | réel | 1/10 heure                  |
| Précipitations dans les N dernières heures                | rrN        | réel | mm                          |
| Phénomène spécial   | phenspeN   | réel | <a href="#">code</a> (3778) |
| Nébulosité cche nuageuse N                                | nnuageN    | int  | octa                        |
| Type nuage N  | ctypeN     | int  | <a href="#">code</a> (0500) |
| Hauteur de base N   | hnuageN    | int  | m                           |

car : caractère ASCII, int : nombre entier, réel : nombre réel (avec décimale).

Les nombres entre parenthèses après le mot "code" sont les numéros de table de code de l'OMM (Organisation Mondiale de la Météorologie).

Vous pouvez cliquer sur le mot code pour accéder directement à ces tables sur le site de l'OMM

Figure 4. Description des 59 colonnes du fichier

## A.5. Correspondances numer\_sta et communes des stations de mesure

Table 4. Correspondance entre codes et valeurs de la colonne numer\_sta

| ID    | Nom                     | Latitude  | Longitude | Altitude |
|-------|-------------------------|-----------|-----------|----------|
| 07005 | ABBEVILLE               | 50.136000 | 1.834000  | 69       |
| 07015 | LILLE-LESQUIN           | 50.570000 | 3.097500  | 47       |
| 07020 | PTE DE LA HAGUE         | 49.725167 | -1.939833 | 6        |
| 07027 | CAEN-CARPIQUET          | 49.180000 | -0.456167 | 67       |
| 07037 | ROUEN-BOOS              | 49.383000 | 1.181667  | 151      |
| 07072 | REIMS-PRUNAY            | 49.209667 | 4.155333  | 95       |
| 07110 | BREST-GUIPAVAS          | 48.444167 | -4.412000 | 94       |
| 07117 | PLOUMANAC'H             | 48.825833 | -3.473167 | 55       |
| 07130 | RENNES-ST<br>JACQUES    | 48.068833 | -1.734000 | 36       |
| 07139 | ALENCON                 | 48.445500 | 0.110167  | 143      |
| 07149 | ORLY                    | 48.716833 | 2.384333  | 89       |
| 07168 | TROYES-<br>BARBEREY     | 48.324667 | 4.020000  | 112      |
| 07181 | NANCY-OCHEY             | 48.581000 | 5.959833  | 336      |
| 07190 | STRASBOURG-<br>ENTZHEIM | 48.549500 | 7.640333  | 150      |
| 07207 | BELLE ILE-LE<br>TALUT   | 47.294333 | -3.218333 | 34       |
| 07222 | NANTES-<br>BOUGUENNAIS  | 47.150000 | -1.608833 | 26       |
| 07240 | TOURS                   | 47.444500 | 0.727333  | 108      |
| 07255 | BOURGES                 | 47.059167 | 2.359833  | 161      |
| 07280 | DIJON-LONGVIC           | 47.267833 | 5.088333  | 219      |
| 07299 | BALE-MULHOUSE           | 47.614333 | 7.510000  | 263      |
| 07314 | PTE DE<br>CHASSIRON     | 46.046833 | -1.411500 | 11       |
| 07335 | POITIERS-BIARD          | 46.593833 | 0.314333  | 123      |
| 07434 | LIMOGES-<br>BELLEGARDE  | 45.861167 | 1.175000  | 402      |
| 07460 | CLERMONT-FD             | 45.786833 | 3.149333  | 331      |
| 07471 | LE PUY-LOUDES           | 45.074500 | 3.764000  | 833      |
| 07481 | LYON-ST EXUPERY         | 45.726500 | 5.077833  | 235      |

| ID    | Nom                 | Latitude   | Longitude  | Altitude |
|-------|---------------------|------------|------------|----------|
| 07510 | BORDEAUX-MERIGNAC   | 44.830667  | -0.691333  | 47       |
| 07535 | GOURDON             | 44.745000  | 1.396667   | 260      |
| 07558 | MILLAU              | 44.118500  | 3.019500   | 712      |
| 07577 | MONTELMAR           | 44.581167  | 4.733000   | 73       |
| 07591 | EMBRUN              | 44.565667  | 6.502333   | 871      |
| 07607 | MONT-DE-MARSAN      | 43.909833  | -0.500167  | 59       |
| 07621 | TARBES-OSSUN        | 43.188000  | 0.000000   | 360      |
| 07627 | ST GIRONS           | 43.005333  | 1.106833   | 414      |
| 07630 | TOULOUSE-BLAGNAC    | 43.621000  | 1.378833   | 151      |
| 07643 | MONTPELLIER         | 43.577000  | 3.963167   | 2        |
| 07650 | MARIGNANE           | 43.437667  | 5.216000   | 9        |
| 07661 | CAP CEPET           | 43.079333  | 5.940833   | 115      |
| 07690 | NICE                | 43.648833  | 7.209000   | 2        |
| 07747 | PERPIGNAN           | 42.737167  | 2.872833   | 42       |
| 07761 | AJACCIO             | 41.918000  | 8.792667   | 5        |
| 07790 | BASTIA              | 42.540667  | 9.485167   | 10       |
| 61968 | GLORIEUSES          | -11.582667 | 47.289667  | 3        |
| 61970 | JUAN DE NOVA        | -17.054667 | 42.712000  | 9        |
| 61972 | EUROPA              | -22.344167 | 40.340667  | 6        |
| 61976 | TROMELIN            | -15.887667 | 54.520667  | 7        |
| 61980 | GILLOT-AEROPORT     | -20.892500 | 55.528667  | 8        |
| 61996 | NOUVELLE AMSTERDAM  | -37.795167 | 77.569167  | 27       |
| 61997 | CROZET              | -46.432500 | 51.856667  | 146      |
| 61998 | KERGUELEN           | -49.352333 | 70.243333  | 29       |
| 67005 | PAMANDZI            | -12.805500 | 45.282833  | 7        |
| 71805 | ST-PIERRE           | 46.766333  | -56.179167 | 21       |
| 78890 | LA DESIRADE METEO   | 16.335000  | -61.004000 | 27       |
| 78894 | ST-BARTHELEMY METEO | 17.901500  | -62.852167 | 44       |
| 78897 | LE RAIZET AERO      | 16.264000  | -61.516333 | 11       |
| 78922 | TRINITE-CARAVEL     | 14.774500  | -60.875333 | 26       |
| 78925 | LAMENTIN-AERO       | 14.595333  | -60.995667 | 3        |



| ID    | Nom              | Latitude   | Longitude  | Altitude |
|-------|------------------|------------|------------|----------|
| 81401 | SAINT LAURENT    | 5.485500   | -54.031667 | 5        |
| 81405 | CAYENNE-MATOURY  | 4.822333   | -52.365333 | 4        |
| 81408 | SAINT GEORGES    | 3.890667   | -51.804667 | 6        |
| 81415 | MARIPASOULA      | 3.640167   | -54.028333 | 106      |
| 89642 | DUMONT D'URVILLE | -66.663167 | 140.001000 | 43       |

## A.6. Script de récupération des données Météofrance

```
import requests
import time
import gzip
import shutil

#
https://donneespubliques.meteofrance.fr/donnees_libres/Txt/Synop/Archive/synop.201801.
csv.gz
URL_base =
"https://donneespubliques.meteofrance.fr/donnees_libres/Txt/Synop/Archive/synop."
URL_suffixe = ".csv.gz"
OUTPUT_DIR="extractions"
OUTPUT_FILENAME_PREFIX="meteo-"
OUTPUT_FILENAME_EXTENSION=".csv"

for year in range(1996, 2018):
    for month in ["%.2d" % i for i in range(1, 13)]:
        URL_fichier = URL_base + str(year) + str(month) + URL_suffixe
        rep = requests.get(URL_fichier)
        status = rep.status_code
        print("URL <" + rep.url + "> code retour <" + str(status) + ">\n")
        if (status == 200):
            downloaded_filename = OUTPUT_DIR+"/"+ OUTPUT_FILENAME_PREFIX + str(year)
            + "_" + str(month) + OUTPUT_FILENAME_EXTENSION
            # downloaded_filename_gz = downloaded_filename + ".csv.gz"
            with open(downloaded_filename, "wb") as outfile:
                outfile.write(rep.content)
            # with gzip.open(downloaded_filename_gz, 'rb') as f_in,
            open(downloaded_filename, 'wb') as f_out:
                # shutil.copyfileobj(f_in, f_out)
            # http://www.meteofrance.com/robots.txt
            time.sleep(1)
#TODO multithread & temporisation
#TODO temps passe
```

## A.7. Scripts import des données MétéoFrance dans InfluxDB

### A.7.1. Le script lauréat modifié pour les besoins du projet

```
import requests
import json
import gzip
import argparse
import csv
import datetime

from influxdb import InfluxDBClient

epoch = datetime.datetime.utcnow().timestamp()
def unix_time_millis(dt):
    return int((dt - epoch).total_seconds() * 1000)

def loadCsv(inputfilename, servername, user, password, dbname, metric, timecolumn,
timeformat, tagcolumns, fieldcolumns, usegzip, delimiter, batchsize):
    host = servername[0:servername.rfind(':')]
    port = int(servername[servername.rfind(':')+1:])
    #pour le cloud
    #client = InfluxDBClient(host='gigawatt-44bcabba.influxcloud.net', port=8086,
username='f.dunan@probt.com', password='Tototo11!', database=dbname, ssl=True)
    client = InfluxDBClient(host, port, user, password, dbname)
    #print('Deleting database %s'%dbname)
    #client.drop_database(dbname)
    #print('Creating database %s'%dbname)
    #client.create_database(dbname)
    client.switch_user(user, password)

    # format tags and fields
    if tagcolumns:
        tagcolumns = tagcolumns.split(',')
    if fieldcolumns:
        fieldcolumns = fieldcolumns.split(',')

    # open csv
    datapoints = []
    inputfile = open(inputfilename, 'r')
    count = 0
    with open(inputfilename, 'r') as csvfile:
        reader = csv.DictReader(csvfile, delimiter=delimiter)
        for row in reader:
            timestamp =
unix_time_millis(datetime.datetime.strptime(row[timecolumn],timeformat)) * 1000000 #
            in nanoseconds
```

```

tags = {}
for t in tagcolumns:
    v = 0
    if t in row:
        if(row[t] != 'mq'):#FDU
            v = row[t]
        tags[t] = v

fields = {}
for f in fieldcolumns:
    v = 0
    if f in row:
        if(row[f] != 'mq'):#FDU
            v = float(row[f])
    #     else:
    #         v = -999999.0
    fields[f] = v

point = {"measurement": metric, "time": timestamp, "fields": fields,
"tags": tags}

datapoints.append(point)
count+=1

if len(datapoints) % batchsize == 0:
    print('Read %d lines'%count)
    print('Inserting %d datapoints...'%(len(datapoints)))
    response = client.write_points(datapoints)

    if response == False:
        print('Problem inserting points, exiting...')
        exit(1)

    print ("Wrote %d, response: %s" % (len(datapoints), response))

    datapoints = []

# write rest
if len(datapoints) > 0:
    print( 'Read %d lines'%count)
    print( 'Inserting %d datapoints...'%(len(datapoints)))
    response = client.write_points(datapoints)

    if response == False:
        print ('Problem inserting points, exiting...')
        exit(1)

    print ("Wrote %d, response: %s" % (len(datapoints), response))

```

```

print ('Done')

if __name__ == "__main__":
    parser = argparse.ArgumentParser(description='Csv to influxdb.')

    parser.add_argument('-i', '--input', nargs='?', required=True,
                        help='Input csv file.')

    parser.add_argument('-d', '--delimiter', nargs='?', required=False, default=',',
                        help='Csv delimiter. Default: \',\'.')

    parser.add_argument('-s', '--server', nargs='?', default='localhost:8086',
                        help='Server address. Default: localhost:8086')

    parser.add_argument('-u', '--user', nargs='?', default='root',
                        help='User name.')

    parser.add_argument('-p', '--password', nargs='?', default='root',
                        help='Password.')

    parser.add_argument('--dbname', nargs='?', required=True,
                        help='Database name.')

    parser.add_argument('-m', '--metricname', nargs='?', default='value',
                        help='Metric column name. Default: value')

    parser.add_argument('-tc', '--timecolumn', nargs='?', default='timestamp',
                        help='Timestamp column name. Default: timestamp.')

    parser.add_argument('-tf', '--timeformat', nargs='?', default='%Y-%m-%d %H:%M:%S',
                        help='Timestamp format. Default: \'%%Y-%%m-%%d %%H:%%M:%%S\'
e.g.: 1970-01-01 00:00:00')

    parser.add_argument('--fieldcolumns', nargs='?', default='value',
                        help='List of csv columns to use as fields, separated by
comma, e.g.: value1,value2. Default: value')

    parser.add_argument('--tagcolumns', nargs='?', default='host',
                        help='List of csv columns to use as tags, separated by comma,
e.g.: host,data_center. Default: host')

    parser.add_argument('-g', '--gzip', action='store_true', default=False,
                        help='Compress before sending to influxdb.')

    parser.add_argument('-b', '--batchsize', type=int, default=5000,
                        help='Batch size. Default: 5000.')

    args = parser.parse_args()
    loadCsv(args.input, args.server, args.user, args.password, args.dbname,
            args.metricname, args.timecolumn, args.timeformat, args.tagcolumns,

```

```
args.fieldcolumns, args.gzip, args.delimiter, args.batchsize)
```

*source*

<https://github.com/escalate/influxdb-csv-importer>

*prérequis*

- installation InfluxDB par pip

*modifications*

- conversion python3
- gestion des des 'mq'
- désactivation de la création/suppression database automatique
- ajout gestion HTTPS et authentification pour le cloud

### A.7.2. Un essai d'import avec un script utilisant docker non retenu car limité

Création database

```
> create database météo
> use météo
```

Ajout des données dans container

```
09:19:47-user@M40474:~/Bureau/CNAM/git/influxdb-csv-importer(master)$ sudo docker
build --tag=csvimporter .
```

Vérification: header est bien pris en compte

```
10:07:04-user@M40474:~/Bureau/CNAM/git/influxdb-csv-importer(master)$ sudo docker run
csvimporter --delimiter ';' --server '172.17.0.2' --port 8086 --database meteo
--measurement synop --locale fr_FR.UTF-8 --print-columns --verbose meteo-2017_11-
sample.csv
```

```
DEBUG: CSV filename is set to "meteo-2017_11-sample.csv"
```

```
DEBUG: CSV delimter is set to ";"
```

```
DEBUG: InfluxDB sever address is set to "172.17.0.2"
```

```
DEBUG: InfluxDB sever port is set to "8086"
```

```
DEBUG: InfluxDB database is set to "meteo"
```

```
DEBUG: InfluxDB measurement is set to "synop"
```

```
DEBUG: Timestamp format is set to "epoch"
```

```
DEBUG: Timestamp timezone is set to "UTC"
```

```
DEBUG: Locale for ctype values is set to "('fr_FR', 'UTF-8')"
```

```
DEBUG: Locale for numeric values is set to "('fr_FR', 'UTF-8')"
```

```
DEBUG: Locale for monetary values is set to "('fr_FR', 'UTF-8')"
```

```
DEBUG: Toggle for int to float conversion is set to "True"
```

```
[
```

```
    "",
    "ch",
    "cl",
    "cm",
```

```

"cod_tend",
"ctype1",
"ctype2",
"ctype3",
"ctype4",
"date",
"dd",
"etat_sol",
...
"w2",
"ww"
]

```

```

sudo docker run csvimporter --delimiter ';' --server '172.17.0.2' --port 8086
--timestamp-column "date" --timestamp-format "fab_datetime" --database meteo
--measurement synop --locale fr_FR.UTF-8 --column-ignorelist
cod_tend,td,vv,ww,w1,w2,n,nbas,hbas,cl,cm,ch,niv_bar,geop,tend24,tn12,tn24,tx12,tx24,t
minsol,sw,tw,raf10,rafper,per,etat_sol,ht_neige,ssfrai,perssfrai,rr1,rr3,rr6,rr12,rr24
,phenspe1,phenspe2,phenspe3,phenspe4,nnuage1,ctype1,hnuage1,nnuage2,ctype2,hnuage2,nnu
age3,ctype3,hnuage3,nnuage4,ctype4,hnuage4,date --write-data --verbose meteo-2017_11-
sample.csv

```

*source*

<https://github.com/fabio-miranda/csv-to-influxdb>

*modifications*

- contrainte d'import des données dans le container
- modification du format de date

*limite*

pas de gestion des tags influxDB

## A.8. Les caractéristiques du cluster cloud

Order Summary:

Standard I

FREE Trial

**InfluxCloud** is a secure, fully managed database, hosted (on AWS) and managed by InfluxData with all the features of the **InfluxData platform**.

us-west-2 Data Center

4GB RAM/Node

16GB Storage

2 Data Nodes

3 Meta Nodes

Unlimited Community Support

High Availability

~50,000 Series

~75 Writes/s

~20 Queries/s

\$249/mo

\$0.35/hour

Storage Overage: \$20/mo/16GB block

Monthly ☒ Yearly

Change Plan

Figure 5. Caractéristiques du cluster cloud

## A.9. Des commandes de diagnostic

```
influx -execute "show shards" > "shards-$(date +%s).txt"
influx -execute "show stats" > "stats-$(date +%s).txt"
influx -execute "show diagnostics" > "diagnostics-$(date +%s).txt"
curl -o "goroutine-$(date +%s).txt"
"http://localhost:8086/debug/pprof/goroutine?debug=1"
curl -o "heap-$(date +%s).txt" "http://localhost:8086/debug/pprof/heap?debug=1"
```

source : <https://github.com/influxdata/influxdb/issues/7810>

## Références

### Bibliographiques

- J.Delamarche, "Le stockage de Series chronologiques avec InfluxDB", GLMF n°198, novembre 2016, ed. diamond.

### Web

#### *Générales sur InfluxDB*

- Un inventaire de SGBD NOSQL : <https://db-engines.com/en/ranking/time+series+dbms>.
- Y-combinator : [https://en.wikipedia.org/wiki/Y\\_Combinator\\_\(company\)](https://en.wikipedia.org/wiki/Y_Combinator_(company))
- Erplane : <https://techcrunch.com/2013/03/18/errplane-performance-monitoring-and-alert-service-for-web-apps/>
- Limites InfluxDB vue par un site tiers: <https://db-engines.com/en/system/InfluxDB>
- limites InfluxDB vues par InfluxData : [https://docs.influxdata.com/influxdb/v1.2/concepts/insights\\_tradeoffs/](https://docs.influxdata.com/influxdb/v1.2/concepts/insights_tradeoffs/)

#### *Données*

- le site de l'organisation mondiale de la météorologie : <https://public.wmo.int/fr> et son extranet : [https://www.wmo.int/pages/index\\_fr.html](https://www.wmo.int/pages/index_fr.html)
- Source des données météoFrance : [https://donneespubliques.meteofrance.fr/?fond=produit&id\\_produit=90&id\\_rubrique=32](https://donneespubliques.meteofrance.fr/?fond=produit&id_produit=90&id_rubrique=32)

#### *Techniques*

- Pourquoi InfluxDB n'est pas CRUD : <https://docs.influxdata.com/influxdb/v1.4/concepts/crosswalk/#a-note-on-why-influxdb-isn-t-crud>
- kapacitor : <https://www.influxdata.com/time-series-platform/kapacitor/>
- BoltDB : [https://docs.influxdata.com/influxdb/v1.4/concepts/storage\\_engine/#boltdb-and-mmap-b-trees](https://docs.influxdata.com/influxdb/v1.4/concepts/storage_engine/#boltdb-and-mmap-b-trees)
- IDE : <https://github.com/CymaticLabs/InfluxDBStudio>
- Paquet Ubuntu InfluxDB : <https://packages.ubuntu.com/artful/influxdb>



- Image docker officielle influxDB : [https://hub.docker.com/\\_/influxdb/](https://hub.docker.com/_/influxdb/)
- Image docker officielle chronograf : [https://hub.docker.com/\\_/chronograf/](https://hub.docker.com/_/chronograf/)
- CLI influx : <https://docs.influxdata.com/influxdb/v1.4/tools/shell/>
- Import batch en CLI : <https://docs.influxdata.com/influxdb/v1.4/tools/shell/#import-data-from-a-file-with-import>
- L'implémentation Raft d'hashiCorp : <https://github.com/hashicorp/raft>
- Procédure d'installation des meta nodes : [https://docs.influxdata.com/enterprise\\_influxdb/v1.5/production\\_installation/meta\\_node\\_installation/#step-1-modify-the-etc-hosts-file](https://docs.influxdata.com/enterprise_influxdb/v1.5/production_installation/meta_node_installation/#step-1-modify-the-etc-hosts-file)
- Le select et les tags dans la documentation officielle : [https://docs.influxdata.com/influxdb/v1.5/query\\_language/data\\_exploration/#common-issues-with-the-select-statement](https://docs.influxdata.com/influxdb/v1.5/query_language/data_exploration/#common-issues-with-the-select-statement) et <https://docs.influxdata.com/influxdb/v1.5/troubleshooting/frequently-asked-questions/#tag-keys-in-the-select-clause>